


FIGURA 14.2 Cuatro series temporales económicas

Las cuatro series temporales presentan patrones muy diferentes. El tipo de interés de los fondos federales (Figura 14.2a) presenta un patrón similar a la inflación de los precios. El tipo de cambio entre el dólar de EE.UU. y la libra esterlina (Figura 14.2b) muestra una variación discreta tras el colapso, en 1972, del sistema de Bretton Woods de tipos de cambio fijos. El logaritmo del PIB de Japón (Figura 14.2c) muestra un crecimiento relativamente suave, aunque la tasa de crecimiento disminuye en la década de 1970 y de nuevo en la década de 1990. La variación porcentual diaria en el índice de precios de la bolsa de valores NYSE (Figura 14.2d) es esencialmente impredecible, pero su varianza cambia: esta serie muestra «volatilidad agrupada».

correlación serial entre las variaciones porcentuales diarias: si existiera, entonces se podría predecir utilizando las variaciones diarias anteriores y se podría ganar dinero comprando cuando se espera que el mercado suba y vendiendo cuando se espera que baje. Aunque las variaciones son esencialmente impredecibles, la observación detenida de la Figura 14.2d revela patrones en su volatilidad. Por ejemplo, la desviación típica de las variaciones porcentuales diarias fue relativamente grande en 1990-1991 y 1998-2003, y relativamente pequeña en 1995 y 2005. Esta «volatilidad agrupada» se encuentra en muchas series temporales financieras, en la Sección 16.5 se tratan algunos de los modelos econométricos que existen para modelizar este tipo especial de heterocedasticidad.

14.3 Modelos autorregresivos

¿Cuál será la tasa de inflación de los precios, el aumento general de los precios en términos porcentuales, el próximo año? Los inversores de Wall Street se basan en las previsiones de inflación en el momento de decidir la cantidad a pagar por los bonos. Los economistas de los bancos centrales, como el Banco de la Reserva Federal de los EE.UU. utilizan las predicciones de inflación cuando establecen la política monetaria. Las empresas utilizan las predicciones de inflación cuando realizan la previsión de ventas de sus productos, y los gobiernos locales utilizan las predicciones de inflación cuando redactan sus presupuestos para

el año siguiente. En esta sección, se consideran las predicciones realizadas mediante **autorregresión**, un modelo de regresión que relaciona una variable de series temporales con sus valores pasados.

El modelo autorregresivo de primer orden

Si se pretende predecir el futuro de una serie temporal, un buen punto de arranque es el pasado inmediato. Por ejemplo, si se quiere pronosticar la variación de la inflación de este trimestre al siguiente, podría verse si la inflación aumentó o disminuyó el último trimestre. Un método sistemático para predecir la variación en la inflación, ΔInf_t , mediante la variación del trimestre anterior, ΔInf_{t-1} consiste en estimar una regresión MCO de ΔInf_t sobre ΔInf_{t-1} . Esta regresión estimada utilizando los datos desde 1962 hasta 2004, es

$$\widehat{\Delta Inf_t} = 0,017 - 0,238\Delta Inf_{t-1}, \quad (14.7)$$

(0,126) (0,096)

donde, como es habitual, los errores estándar están indicados entre paréntesis debajo de los coeficientes estimados, y $\widehat{\Delta Inf_t}$ es el valor estimado de ΔInf_t en base a la recta de regresión estimada. El modelo de la Ecuación (14.7) se denomina autorregresivo de primer orden: es autorregresivo porque se trata de una regresión de la serie sobre su propio retardo, ΔInf_{t-1} y es de primer orden, ya que solo se utiliza un retardo como regresor. El coeficiente de la Ecuación (14.7) es negativo, por lo que un aumento de la tasa de inflación durante un trimestre está asociado con una disminución de la tasa de inflación en el trimestre siguiente.

Un modelo autorregresivo de primer orden se abrevia mediante AR(1), donde el «1» indica que es de primer orden. El modelo AR(1) poblacional de la serie Y_t es

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + u_t, \quad (14.8)$$

donde u_t es un término de error.

Predicciones y errores de predicción. Supongamos que se dispone de datos históricos sobre Y y se desea predecir su valor futuro. Si Y_t sigue el modelo AR(1) de la Ecuación (14.8) y si β_0 y β_1 son conocidos, entonces la predicción de Y_{T+1} en base a Y_T es $\beta_0 + \beta_1 Y_T$.

En la práctica, β_0 y β_1 son desconocidos, por lo que las predicciones deben basarse en estimaciones de β_0 y β_1 . Se utilizan los estimadores MCO $\hat{\beta}_0$ y $\hat{\beta}_1$, que se calculan utilizando datos históricos. En general, $\hat{Y}_{T+1|T}$ indica la predicción de Y_{T+1} basada en la información hasta el periodo T utilizando un modelo estimado con datos hasta el periodo T . En consecuencia, la predicción basada en el modelo AR(1) de la Ecuación (14.8) es

$$\hat{Y}_{T+1|T} = \hat{\beta}_0 + \hat{\beta}_1 Y_T, \quad (14.9)$$

donde $\hat{\beta}_0$ y $\hat{\beta}_1$ se calculan con los datos históricos disponibles hasta el periodo T .

El **error de predicción** es el error cometido en la predicción; es decir la diferencia entre el valor de Y_{T+1} que realmente sucede y su valor de predicción basado en Y_T :

$$\text{Error de predicción} = Y_{T+1} - \hat{Y}_{T+1|T}. \quad (14.10)$$

Predicciones versus valores de predicción. La predicción *no* es un valor de predicción MCO, y el error de predicción *no* es un residuo MCO. Los valores de predicción MCO se calculan para las observaciones de la muestra utilizada para estimar la regresión. Por el contrario, la predicción se hace para algún periodo más allá del conjunto de los datos utilizados para estimar la regresión, por lo que los datos sobre el valor real de la variable dependiente predicha no se encuentran en la muestra utilizada para estimar la regresión. Del mismo modo, el residuo MCO es la diferencia entre el valor real de Y y su valor de predicción para las observaciones de la muestra, mientras que el error de predicción es la diferencia entre el valor futuro de Y , que no está contenido en la muestra de la estimación, y la predicción de ese valor futuro. Dicho de otra manera, las predicciones y los errores de predicción se refieren a observaciones «fuera de la muestra», mientras que los valores de predicción y los residuos se refieren a observaciones «en la muestra».

Raíz del error cuadrático medio de predicción. La **raíz del error cuadrático de predicción (RECMF)** es una medida de la magnitud del error de predicción, es decir, de la magnitud de un error estándar cometido con un modelo de predicción. La RECMF es la raíz cuadrada de la media del error de predicción al cuadrado:

$$\text{RECMF} = \sqrt{E[(Y_{T+1} - \hat{Y}_{T+1|T})^2]}. \quad (14.11)$$

La RECMF tiene dos fuentes de error: el error que surge debido a que los valores futuros de u_t son desconocidos y el error cometido en la estimación de los coeficientes β_0 y β_1 . Si la primera fuente de error es mucho mayor que la segunda, tal y como puede ocurrir si el tamaño de la muestra es grande, entonces la RECMF es aproximadamente $\sqrt{\text{var}(u_t)}$, la desviación típica del error u_t de la autorregresión poblacional [Ecuación (14.8)]. La desviación típica de u_t se estima a su vez mediante el error estándar de la regresión (ESR; véase la Sección 4.3). Por lo tanto, si la incertidumbre que surge de la estimación de los coeficientes de regresión es lo suficientemente pequeña como para ser ignorada, la RECMF se puede estimar mediante el error estándar de la regresión. La estimación de la RECMF que incluye ambas fuentes del error de predicción se recoge en la Sección 14.4.

Aplicación a la inflación. ¿Cuál es la predicción para la inflación en el primer trimestre de 2005 (2005:I) que un economista habría hecho en 2004:IV, en base a la estimación del modelo AR(1) de la Ecuación (14.7) (estimado utilizando los datos disponibles hasta 2004:IV)? A partir de la Tabla 14.1, la tasa de inflación en 2004:IV fue el 3,5 % (por lo que $\text{Inf}_{2004:\text{IV}} = 3,5$), un incremento de 1,9 puntos porcentuales a partir de 2004:III (por lo que $\Delta \text{Inf}_{2004:\text{IV}} = 1,9$). Al introducir estos valores en la Ecuación (14.7), la predicción para la variación de la inflación de 2004:IV hasta 2005:I es $\widehat{\Delta \text{Inf}}_{2005:\text{I}|2004:\text{IV}} = 0,017 - 0,238 \times \Delta \text{Inf}_{2004:\text{IV}} = 0,017 - 0,238 \times 1,9 = -0,43 \cong -0,4$ (redondeado al primer decimal). La tasa de inflación prevista es la tasa de inflación pasada más su variación prevista:

$$\widehat{\Delta \text{Inf}}_{T+1|T} = \text{Inf}_T + \widehat{\Delta \text{Inf}}_{T+1|T}. \quad (14.12)$$

Debido a que $\text{Inf}_{2004:\text{IV}} = 3,5$ % y la variación prevista en la tasa de inflación desde 2004:IV hasta 2005:I, es $-0,4$, la predicción para la tasa de inflación en 2005:I es $\widehat{\text{Inf}}_{2005:\text{I}|2004:\text{IV}} = \text{Inf}_{2004:\text{IV}} + \widehat{\Delta \text{Inf}}_{2005:\text{I}|2004:\text{IV}} = 3,5 \text{ \%} - 0,4 \text{ \%} = 3,1 \text{ \%}$. Por lo tanto, el modelo AR(1) predice que la inflación bajará ligeramente del 3,5 % en 2004:IV al 3,1 % en 2005:I.

¿Cuál fue la precisión de la predicción AR(1)? De acuerdo con la Tabla 14.1, el valor real de la inflación en 2005:I fue de un 2,4 %, por lo que la predicción de AR(1) fue mayor en 0,7 puntos porcentuales; es decir, el error de predicción es de $-0,7$. El $\bar{R}^2$ del modelo AR(1) de la Ecuación (14.7) es solamente 0,05, por lo que la variación retardada de la inflación explica una proporción muy pequeña de la variación de la inflación en la muestra utilizada para el ajuste de la autorregresión. Este $\bar{R}^2$ tan bajo es consistente con el pobre pronóstico de la inflación en 2005:I al que da lugar la utilización de la Ecuación (14.7). De manera más general, el bajo $\bar{R}^2$ sugiere que este modelo AR(1) pronosticará tan solo una pequeña parte de la variabilidad de la variación de la inflación.

El error estándar de la regresión de la Ecuación (14.7) es 1,65; ignorando la incertidumbre derivada de la estimación de los coeficientes, la estimación de la RECMF para las predicciones basadas en la Ecuación (14.7) por lo tanto es de 1,65 puntos porcentuales.

El modelo autorregresivo de orden p

El modelo AR(1) utiliza Y_{t-1} para predecir Y_t , pero al hacerlo ignora información potencialmente útil acerca del pasado más lejano. Una manera de incorporar esta información consiste en incluir retardos adicionales en el modelo AR(1); lo que da lugar al modelo autorregresivo de orden p , o modelo AR(p).

El **modelo autorregresivo de orden p** [el modelo **AR(p)**] representa Y_t como una función lineal de sus primeros p valores retardados, es decir, en el modelo AR(p), los regresores son $Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$, más un término independiente. El número de retardos, p , incluidos en un modelo AR(p) se denomina orden, o longitud de los retardos, de la autorregresión.

**CONCEPTO
CLAVE****14.3****Modelos autorregresivos**

El modelo autorregresivo de orden p [el modelo $AR(p)$] representa Y_t como una función lineal de sus p primeros valores retardados:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \cdots + \beta_p Y_{t-p} + u_t, \quad (14.14)$$

donde $E(u_t | Y_{t-1}, Y_{t-2}, \dots) = 0$. El número de retardos p se denomina orden, o longitud de los retardos, de la autorregresión.

Por ejemplo, un modelo $AR(4)$ para la variación de la inflación utiliza como regresores a los cuatro primeros retardos de la variación de la inflación. Estimado por MCO para el periodo 1962-2004, el modelo $AR(4)$ es

$$\widehat{\Delta Inf_t} = 0,02 - 0,26\Delta Inf_{t-1} - 0,32\Delta Inf_{t-2} + 0,16\Delta Inf_{t-3} - 0,03\Delta Inf_{t-4}. \quad (14.13)$$

(0,12) (0,09) (0,08) (0,08) (0,09)

Los coeficientes de los tres últimos retardos adicionales de la Ecuación (14.13) son conjuntamente significativamente distintos de cero al nivel de significación del 5 %: el estadístico F es 6,91 (p -valor $< 0,001$). Esto se ve reflejado en una mejora en el $\bar{R}^2$ desde el 0,05 para el modelo $AR(1)$ de la Ecuación (14.7) hasta el 0,18 para el modelo $AR(4)$. Del mismo modo, el ESR del modelo $AR(4)$ de la Ecuación (14.13) es de 1,52, lo que supone una mejora sobre el ESR del modelo $AR(1)$, que es 1,65.

El modelo $AR(p)$ se resume en el Concepto clave 14.3.

Propiedades de la predicción y del término de error en el modelo $AR(p)$. El supuesto de que la esperanza condicional de u_t es igual a cero, dados los valores pasados de Y_t [es decir, $E(u_t | Y_{t-1}, Y_{t-2}, \dots) = 0$], tiene dos implicaciones importantes.

La primera implicación es que la mejor predicción para Y_{T+1} basada en su historia completa solamente depende de los p valores pasados más recientes. En concreto, sea $Y_{T+1|T} = E(Y_{T+1} | Y_T, Y_{T-1}, \dots)$ la expresión de la media condicional de Y_{T+1} dada su historia completa. Por tanto, $Y_{T+1|T}$, tiene la menor RECMF de cualquier predicción basada en la historia de Y (Ejercicio 14.5). Si Y_t sigue un proceso $AR(p)$, entonces la mejor predicción de Y_{T+1} basada en $Y_T, Y_{T-1}, \dots$ es

$$Y_{T+1|T} = \beta_0 + \beta_1 Y_T + \beta_2 Y_{T-1} + \cdots + \beta_p Y_{T-p+1}, \quad (14.15)$$

lo cual se desprende del modelo $AR(p)$ de la Ecuación (14.14) y del supuesto de que $E(u_t | Y_{t-1}, Y_{t-2}, \dots) = 0$. En la práctica, los coeficientes $\beta_0, \beta_1, \dots, \beta_p$ son desconocidos, por lo que en realidad las predicciones realizadas mediante un modelo $AR(p)$ utilizan la Ecuación (14.15) con los coeficientes estimados.

La segunda implicación es que los errores u_t están serialmente incorrelacionados, un resultado que se deriva de la Ecuación (2.27) (Ejercicio 14.5).

Aplicación a la inflación. ¿Cuál es la predicción para la inflación en 2005:I a partir de los datos disponibles hasta 2004:IV, en base al modelo $AR(4)$ para la inflación de la Ecuación (14.13)? Para calcular esta predicción, se sustituyen los valores de la variación en la inflación de cada uno de los cuatro trimestres de 2004 en la Ecuación (14.13): $\widehat{\Delta Inf}_{2005:I|2004:IV} = 0,02 - 0,26\Delta Inf_{2004:IV} - 0,32\Delta Inf_{2004:III} + 0,16\Delta Inf_{2004:II} - 0,03\Delta Inf_{2004:I} = 0,02 - 0,26 \times 1,9 - 0,32 \times (-2,8) + 0,16 \times 0,6 - 0,03 \times 2,9 \cong 0,4$, donde los valores de 2004 para la variación de la inflación se han tomado de la última columna de la Tabla 14.1.

La previsión correspondiente para la inflación en 2005:I es el valor de la inflación en 2004:IV, más la variación estimada; es decir, 3,5 % + 0,4 % = 3,9 %. El error de predicción es el valor real, 2,4 %, menos la predicción, o 2,4 % - 3,9 % = 1,5, mayor en valor absoluto que el error de predicción $AR(1)$ de -0,7 puntos porcentuales.

¿Se puede batir al mercado? Parte I

¿Alguna vez ha soñado con ser rico rápidamente ganándole al mercado de valores? Si se cree que el mercado va a subir, deberían comprarse acciones hoy para ser vendidas más tarde, antes de que el mercado vuelva a caer. Si se es bueno al prever las variaciones de los precios de las acciones, entonces esta estrategia de mercado activa dará lugar a mejores rendimientos que una estrategia pasiva de «comprar y mantener» que consista en comprar acciones y simplemente mantenerlas. El truco, por supuesto, es disponer de una previsión fiable sobre los rendimientos futuros de las acciones.

Las predicciones basadas en los valores pasados de la rentabilidad de las acciones a veces se denominan predicciones del «momentum»: si el valor de una acción ha aumentado este mes, tal vez se haya generado un movimiento de impulso y aumente otra vez el mes siguiente. Si es así, entonces los rendimientos estarán correlacionados y el modelo autorregresivo proporcionará predicciones útiles. Se puede llevar a cabo una estrategia basada en el momentum o impulso de una acción específica o de un índice bursátil que mida el valor global del mercado.

En la Tabla 14.3 se presentan algunos modelos autorregresivos para la rentabilidad extraordinaria de un índice amplio de los precios de acciones denominado índice CRSP ponderado, utilizando datos mensuales desde 1960:1 hasta 2002:12. La rentabilidad extraordinaria mensual es la ganancia, en términos porcentuales, obtenida por la compra de una acción al final del mes anterior y su venta a finales de este mes, menos la ganancia que se hubiera obtenido de haber comprado un activo seguro (letras del tesoro norteamericano). La rentabilidad de las acciones incluye la ganancia (o pérdida) de capital debida a la variación en el precio, además de los dividendos percibidos a lo largo del mes. Los datos se describen de manera más detallada en el Apéndice 14.1.

Lamentablemente, los resultados de la Tabla 14.3 son negativos. Los coeficientes de los rendimientos retardados en el modelo AR(1) no son estadísticamente significativos, y no se puede rechazar la hipótesis nula de que los coeficientes de los rendimientos retardados son iguales a cero en los modelos AR(2) o AR(4). De hecho, el R^2 ajustado de uno de los mode-

TABLA 14.3 Modelos autorregresivos para la rentabilidad extraordinaria mensual de las acciones, 1960:1-2002:12			
Variable dependiente: rentabilidad extraordinaria del índice CRSP			
	(1)	(2)	(3)
Especificación	AR(1)	AR(2)	AR(4)
Variables explicativas			
Rentabilidad extraordinaria _{t-1}	0,050 (0,051)	0,053 (0,051)	0,054 (0,051)
Rentabilidad extraordinaria _{t-2}		-0,053 (0,048)	-0,054 (0,048)
Rentabilidad extraordinaria _{t-3}			0,009 (0,050)
Rentabilidad extraordinaria _{t-4}			-0,016 (0,047)
Término independiente	0,312 (0,197)	0,328 (0,199)	0,331 (0,202)
Estadístico <i>F</i> para los coeficientes de los retardos de la rentabilidad extraordinaria (<i>p</i> -valor)	0,968 (0,325)	1,342 (0,261)	0,707 (0,587)
$\bar{R}^2$	0,0006	0,0014	-0,0022
Notas: La rentabilidad extraordinaria se mide en términos porcentuales para un mes. Los datos se describen en el Apéndice 14.1. Todas las regresiones están estimadas para el periodo 1960:1-2002:12 (<i>T</i> = 516 observaciones), con valores iniciales de las variables retardadas tomados de observaciones anteriores. Las entradas en las filas de las variables explicativas son los coeficientes de esos regresores, los errores estándar aparecen entre paréntesis. Las dos últimas filas presentan los valores de los estadísticos <i>F</i> para contrastar la hipótesis de que los coeficientes de los retardos de la rentabilidad extraordinaria en la regresión, son iguales a cero, con su <i>p</i> -valor entre paréntesis, y el R^2 ajustado.			

(continúa)

los es negativo y los de los otros dos son solo ligeramente positivos, lo que sugiere que ninguno de estos modelos es útil para la predicción.

Estos resultados negativos son consistentes con la teoría de que los mercados de capitales son eficientes, que sostiene que la rentabilidad extraordinaria debe ser impredecible, debido a que el precio de los valores ya refleja toda la información disponible en el mercado. El razonamiento es sencillo: si los par-

ticipantes en el mercado creen que una acción tendrá una rentabilidad extraordinaria positiva el mes que viene, entonces comprarán esa acción ahora; pero si lo hacen, subirá el precio de las acciones hasta exactamente el punto en que no exista una rentabilidad extraordinaria esperada. Como resultado, no debería ser posible pronosticar una rentabilidad extraordinaria futura mediante el uso de la información pasada públicamente disponible, al menos utilizando las regresiones de la Tabla 14.3.

14.4 Regresión de series temporales con predictores adicionales y modelo autorregresivo de retardos distribuidos

La teoría económica a menudo sugiere otras variables que podrían ayudar a predecir la variable de interés. Esas otras variables, o predictores, se pueden agregar a una autorregresión para dar lugar a un modelo de regresión de series temporales con varios predictores. Al añadir otras variables a una regresión y sus retardos, el resultado obtenido es un modelo autorregresivo de retardos distribuidos.


Predicción de la variación de la tasa de inflación mediante los valores pasados de la tasa de desempleo

Un valor alto de la tasa de desempleo suele estar asociado con una futura disminución de la tasa de inflación. Esta relación negativa conocida como curva de Phillips de corto plazo, es evidente en el diagrama de dispersión de la Figura 14.3, en el que las variaciones año a año de la tasa de inflación de los precios están representadas junto con la tasa de desempleo del año anterior. Por ejemplo, en 1982 la tasa de desempleo promedió un 9,7 %, y durante el año siguiente la tasa de inflación cayó al 2,9 %. En total, la correlación en la Figura 14.3 es -0.36 .

El diagrama de dispersión de la Figura 14.3 sugiere que los valores pasados de la tasa de desempleo podrían contener información acerca del curso futuro de la inflación que no se encuentra ya contenida en las

FIGURA 14.3 Diagrama de dispersión de la variación de la inflación entre el año t y el año $t+1$ versus la tasa de desempleo en el año t , 1961-2004

En 1982, la tasa de desempleo en EE.UU. fue del 9,7 % y la tasa de inflación en 1983 cayó al 2,9 % (el punto grande). En general, los valores altos de la tasa de desempleo en el año t suelen estar seguidos de disminuciones en la tasa de inflación de los precios el año siguiente, año $t+1$, con una correlación de $-0,36$.



variaciones pasadas de la inflación. Esta suposición resulta comprobable fácilmente ampliando el modelo AR(4) de la Ecuación (14.13) para incluir el primer retardo de la tasa de desempleo:

$$\begin{aligned}\widehat{\Delta Inf_t} = & 1,28 - 0,31\Delta Inf_{t-1} - 0,39\Delta Inf_{t-2} + 0,09\Delta Inf_{t-3} \\ & (0,53) \quad (0,09) \quad (0,09) \quad (0,08) \\ & - 0,08\Delta Inf_{t-4} - 0,21Desemp_{t-1} \\ & (0,09) \quad (0,09)\end{aligned}\quad (14.16)$$

El estadístico t , para la variable $Desemp_{t-1}$ es $-2,23$, por lo que este término es significativo al nivel del 5 %. El $\bar{R}^2$ de esta regresión es 0,21, una mejora sobre el $\bar{R}^2$ del modelo AR(4) de 0,18.

La predicción de la variación de la inflación en 2005:I, se obtiene mediante la sustitución de los valores de la variación de la inflación en 2004 en la Ecuación (14.16), junto con el valor de la tasa de desempleo en 2004:IV (que es del 5,4 %); la predicción resultante es $\widehat{\Delta Inf}_{2005:I|2004:IV} = 0,4$. Por lo tanto el pronóstico de la inflación en 2005:I es 3,5 % + 0,4 % = 3,9 %, y el error de predicción es $-1,5$ %.

Si un retardo de la tasa de desempleo resulta útil para predecir la inflación, varios retardos podrían resultar aún más útiles; mediante la adición de tres retardos adicionales de la tasa de desempleo se obtiene

$$\begin{aligned}\widehat{\Delta Inf_t} = & 1,30 - 0,42\Delta Inf_{t-1} - 0,37\Delta Inf_{t-2} + 0,06\Delta Inf_{t-3} - 0,04\Delta Inf_{t-4} \\ & (0,44) \quad (0,08) \quad (0,09) \quad (0,08) \quad (0,08) \\ & - 2,64Desemp_{t-1} + 3,04Desemp_{t-2} - 0,38Desemp_{t-3} - 0,25Desemp_{t-4}. \\ & (0,46) \quad (0,86) \quad (0,89) \quad (0,45)\end{aligned}\quad (14.17)$$

El estadístico F para el contraste de significación conjunta de los retardos desde el segundo hasta el cuarto de la tasa de desempleo es igual a 10,76 (p -valor $< 0,001$), por lo que son conjuntamente significativos. El $\bar{R}^2$ de la regresión de la Ecuación (14.17) es 0,34, una sólida mejora sobre el 0,21 de la Ecuación (14.16). El estadístico F sobre todos los coeficientes de la tasa de desempleo es 8,91 (p -valor $< 0,001$), lo que indica que este modelo representa una mejora estadísticamente significativa con respecto al modelo AR(4) de la Sección 14.3 [Ecuación (14.13)]. El error estándar de la regresión de la Ecuación (14.17) es 1,36, una mejora sustancial sobre el ESR de 1,52 para el modelo AR(4).

La predicción de la variación de la tasa de inflación desde 2004:IV hasta 2005:I; utilizando la Ecuación (14.17) se calcula sustituyendo los valores de las variables en la ecuación. La tasa de desempleo fue del 5,7 % en 2004:I, del 5,6 % en 2004:II, y del 5,4 % en 2004:III y 2004:IV. La predicción para la variación de la inflación desde 2004:IV hasta 2005:I, en base a la Ecuación (14.17), es

$$\begin{aligned}\widehat{\Delta Inf}_{2005:I|2004:IV} = & 1,30 - 0,42 \times 1,9 - 0,37 \times (-2,8) + 0,06 \times 0,6 - 0,04 \\ & \times 2,9 - 2,66 \times 5,4 + 0,34 \times 5,4 - 0,38 \times 5,6 - 0,25 \times 5,7 = 0,1.\end{aligned}\quad (14.18)$$

Por lo tanto la predicción de la inflación para 2005:I es de 3,5 % + 0,1 % = 3,6 %. El error de predicción es $-1,2$.

El modelo autorregresivo de retardos distribuidos. Cada uno de los modelos de las Ecuaciones (14.16) y (14.17) es un **modelo autorregresivo de retardos distribuidos (ARD)**: «autorregresivo» porque están incluidos los valores retardados de la variable dependiente como variables explicativas, como en una autorregresión, y de «retardos distribuidos» porque la regresión incluye asimismo varios retardos (una «distribución de retardos») de un predictor adicional. En general, un modelo autorregresivo de retardos distribuidos con p retardos de la variable dependiente Y_t y q retardos de un predictor adicional X_t se denomina modelo **ARD(p, q)**. En esta notación, el modelo de la Ecuación (14.16) es un modelo ARD(4,1) y el modelo de la Ecuación (14.17) es un modelo ARD(4,4).

El modelo autorregresivo de retardos distribuidos se resume en el Concepto clave 14.4. Con todas estas variables explicativas, la notación de la Ecuación (14.19) resulta algo engorrosa, por lo que la notación alternativa opcional, basada en el denominado operador de retardos, se presenta en el Apéndice 14.3.

**CONCEPTO
CLAVE****14.4****El modelo autorregresivo de retardos distribuidos**

El modelo autorregresivo de retardos distribuidos con p retardos de Y_t y q retardos de X_t , denominado $ARD(p, q)$, es

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \cdots + \beta_p Y_{t-p} + \delta_1 X_{t-1} + \delta_2 X_{t-2} + \cdots + \delta_q X_{t-q} + u_t, \quad (14.19)$$

donde $\beta_0, \beta_1, \dots, \beta_p, \delta_1, \dots, \delta_q$ son coeficientes desconocidos y u_t es el término de error con $E(u_t | Y_{t-1}, Y_{t-2}, \dots, X_{t-1}, X_{t-2}, \dots) = 0$.

El supuesto de que los errores en el modelo ARD tienen una media condicional igual a cero dados todos los valores pasados de Y y X , es decir, que $E(u_t | Y_{t-1}, Y_{t-2}, \dots, X_{t-1}, X_{t-2}, \dots) = 0$, implica que ningún retardo adicional ni de Y ni de X pertenece al modelo ARD. En otras palabras, las longitudes de los retardos p y q son las verdaderas longitudes de los retardos, y los coeficientes de los retardos adicionales son iguales a cero.

El modelo ARD contiene retardos de la variable dependiente (la componente autorregresiva) y un retardo distribuido de un único predictor adicional, X . Sin embargo, en general, las predicciones pueden mejorarse mediante la utilización de varios predictores. Pero antes de pasar al modelo general de series temporales con varios predictores, se introduce en primer lugar el concepto de estacionariedad, que será utilizado en este análisis.

Estacionariedad

El análisis de regresión de datos series temporales necesariamente utiliza los datos pasados para cuantificar las relaciones históricas. Si el futuro es como el pasado, entonces estas relaciones históricas pueden utilizarse para predecir el futuro. Pero si el futuro es fundamentalmente distinto del pasado, entonces esas relaciones históricas no podrán ser guías fiables para el futuro.

En el contexto de la regresión de series temporales, la idea de que las relaciones históricas pueden generalizarse para el futuro está formalizada en el concepto de **estacionariedad**. La definición precisa de la estacionariedad, que se ofrece en el Concepto clave 14.5, es que la distribución de probabilidad de la variable de series temporales no cambia en el tiempo.

**CONCEPTO
CLAVE****14.5****Estacionariedad**

Una serie temporal Y_t es *estacionaria* si su distribución de probabilidad no varía en el tiempo, es decir, si la distribución conjunta de $(Y_{s+1}, Y_{s+2}, \dots, Y_{s+T})$ no depende de s sea cual sea el valor de T ; de lo contrario, se dice que Y_t es *no estacionaria*. Dos series temporales, X_t e Y_t , se dice que son *conjuntamente estacionarias* si la distribución conjunta de $(X_{s+1}, Y_{s+1}, X_{s+2}, Y_{s+2}, \dots, X_{s+T}, Y_{s+T})$ no depende de s , independientemente del valor de T . La estacionariedad requiere que el futuro sea como el pasado, al menos en un sentido probabilístico.

Regresión de series temporales con varios predictores

El modelo general de regresión de series temporales con varios predictores amplía el modelo ARD para incluir varios predictores y sus retardos. El modelo se resume en el Concepto clave 14.6. La presencia de varios predictores y de sus retardos lleva a que se utilice un doble subíndice en los coeficientes de regresión y los regresores.

**CONCEPTO
CLAVE**
14.6
Regresión de series temporales con varios predictores

El modelo general de regresión de series temporales permite k predictores adicionales, en el que se incluyen q_1 retardos del primer predictor, q_2 retardos del segundo predictor, y así sucesivamente:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \cdots + \beta_p Y_{t-p} + \delta_{11} X_{1t-1} + \delta_{12} X_{1t-2} + \cdots + \delta_{1q_1} X_{1t-q_1} + \cdots + \delta_{k1} X_{kt-1} + \delta_{k2} X_{kt-2} + \cdots + \delta_{kq_k} X_{kt-q_k} + u_t, \quad (14.20)$$

donde

1. $E(u_t | Y_{t-1}, Y_{t-2}, \dots, X_{1t-1}, X_{1t-2}, \dots, X_{kt-1}, X_{kt-2}, \dots) = 0$
2. (a) Las variables aleatorias $(Y_t, X_{1t}, \dots, X_{kt})$ presentan una distribución estacionaria, y (b) $(Y_t, X_{1t}, \dots, X_{kt})$ y $(Y_{t-j}, X_{1t-j}, \dots, X_{kt-j})$ pasan a ser independientes cuando j se hace grande.
3. Los valores extremos elevados son poco probables: $X_{1t}, \dots, X_{kt}, Y_t$ presentan momentos de cuarto orden finitos y distintos de cero.
4. No existe multicolinealidad perfecta.

Los supuestos del modelo de regresión de series temporales. Los supuestos del Concepto clave 14.6 modifican los cuatro supuestos de mínimos cuadrados del modelo de regresión múltiple para datos de sección cruzada (Concepto clave 6.4) para los datos de series temporales.

El primer supuesto es que u_t tiene una media condicional igual a cero, dadas todas las variables explicativas y los retardos adicionales de las variables explicativas además de los retardos incluidos en la regresión. Este supuesto amplía el supuesto de los modelos AR y ARD e implica que la mejor predicción de Y_t utilizando todos los valores pasados de Y y de las X está dada por la regresión de la Ecuación (14.20).

El segundo supuesto de mínimos cuadrados para datos de sección cruzada (Concepto clave 6.4) es que $(X_{1i}, \dots, X_{ki}, Y_i)$, $i = 1, \dots, n$, son independientes e idénticamente distribuidas (i.i.d.). El segundo supuesto para la regresión de series temporales sustituye al supuesto de i.i.d. por otro más apropiado con dos partes. La parte (a) es que los datos se hayan obtenido a partir de una distribución estacionaria de manera que la distribución de los datos hoy es la misma que su distribución en el pasado. Este supuesto es una versión para series temporales de la parte «idénticamente distribuidas» del supuesto i.i.d.: el requisito para sección cruzada de que cada extracción sea idénticamente distribuida se sustituye por el requisito para series temporales de que la distribución conjunta de las variables, *incluyendo los retardos*, no cambie en el tiempo. En la práctica, muchas series temporales económicas parecen ser no estacionarias, lo que significa que este supuesto puede no cumplirse en algunas situaciones concretas. Si las variables de series temporales son no estacionarias, entonces pueden aparecer uno o varios problemas en la regresión de series temporales: la predicción puede estar sesgada, la predicción puede ser ineficiente (pueden existir predicciones alternativas basadas en los mismos datos con una menor varianza), o la inferencia estadística basada en los MCO convencionales (por ejemplo, la realización de un contraste de hipótesis mediante la comparación del estadístico t MCO con ± 1.96) puede resultar engañosa. La concreción de cuál de estos problemas aparece, así como su remedio, depende de la fuente de la ausencia de estacionariedad. En las Secciones 14.6 y 14.7, se estudian los problemas que plantean los contrastes para su detección, así como las soluciones disponibles para dos tipos importantes de no estacionariedad desde el punto de vista empírico de las series temporales económicas, las tendencias y los cambios estructurales. Sin embargo, por ahora simplemente se supone que las series son conjuntamente estacionarias y por lo tanto nos centraremos en la regresión con variables estacionarias.

La parte (b) del segundo supuesto requiere que las variables aleatorias sean independientemente distribuidas cuando son muchos los periodos de tiempo que las separan. Esto reemplaza el requisito para sección cruzada de que las variables estén independiente distribuidas entre una observación y la siguiente por el requisito para series temporales de que estén independientemente distribuidas cuando están separadas largos

periodos de tiempo. Este supuesto se denomina a veces **dependencia débil**, y asegura que en muestras grandes exista aleatoriedad suficiente en los datos como para que se cumpla la ley de los grandes números y el teorema central del límite. No se proporciona un enunciado matemático preciso de la condición de dependencia débil; en su lugar, se remite al lector a Hayashi (2000, Capítulo 2).

El tercer supuesto, que es el mismo que el tercer supuesto de mínimos cuadrados para datos de sección cruzada, es que los valores extremos elevados son poco probables, precisado en forma matemática supone que todas las variables presentan momentos de cuarto orden finitos y distintos de cero.

Por último, el cuarto supuesto, que del mismo modo es igual que para los datos de sección cruzada, es que los regresores no presenten multicolinealidad perfecta.

Inferencia estadística y contraste de causalidad de Granger. Bajo los supuestos del Concepto clave 14.6, la inferencia sobre los coeficientes de regresión utilizando MCO se realiza de la misma manera que es habitual para datos de sección cruzada.

Una aplicación útil del estadístico F para la predicción en series de temporales consiste en contrastar si los retardos de uno de los regresores incluidos tienen contenido predictivo útil, aparte de los otros regresores del modelo. La afirmación de que una variable no posee contenido predictivo corresponde a la hipótesis nula de que los coeficientes de todos los retardos de la variable son iguales a cero. El estadístico F para el contraste de esta hipótesis nula se denomina **estadístico de causalidad de Granger**, y el contraste asociado se denomina **contraste de causalidad de Granger** (Granger, 1969). Este contraste se resume en el Concepto clave 14.7.

La causalidad de Granger tiene poco que ver con la causalidad en el sentido que se utiliza en otras partes de este libro. En el Capítulo 1, se definía la causalidad en términos de un experimento aleatorizado controlado ideal, en el que los diferentes valores de X se aplicaban de forma experimental y se observaba el efecto consiguiente sobre Y . Por el contrario, la causalidad de Granger significa que si X causa a Y en el sentido de Granger, entonces X es un predictor útil de Y , dadas las otras variables de la regresión. Si bien la «predictibilidad en el sentido de Granger» es un término más preciso que la «causalidad en el sentido de Granger», esta última se ha convertido en parte de la jerga de la econometría.

Como ejemplo, puede considerarse la relación entre la variación de la tasa de inflación y sus valores pasados y los valores pasados de la tasa de desempleo. El estadístico F basado en las estimaciones MCO de la Ecuación (14.17), para el contraste de la hipótesis nula de que los coeficientes de los cuatro retardos de la tasa de desempleo son iguales a cero es 8,91 (p -valor $< 0,001$): en la jerga del Concepto clave 14.7, se puede concluir (al 1 % de nivel de significación) que la tasa de desempleo causa en el sentido de Granger las variaciones en la tasa de inflación. Esto *no* significa necesariamente que una variación de la tasa de desempleo causará —en el sentido del Capítulo 1— una variación posterior en la tasa de inflación. Lo que *sí* quiere decir es que los valores pasados de la tasa de desempleo parece que contienen información que resulta útil para predecir los cambios en la tasa de inflación, más allá de la contenida en los valores pasados de la tasa de inflación.

**CONCEPTO
CLAVE**

14.7

Contraste de causalidad de Granger (contraste de contenido predictivo)

El estadístico para el contraste de causalidad de Granger es el estadístico F para el contraste de la hipótesis de que los coeficientes de todos los valores de una de las variables de la Ecuación (14.20) (por ejemplo, los coeficientes de X_{1t-1} , X_{1t-2} , ..., X_{1t-q_1}) son iguales a cero. Esta hipótesis nula implica que estos regresores no tienen contenido predictivo para Y_t más allá del contenido en los otros regresores, y el contraste de esta hipótesis nula se denomina contraste de causalidad de Granger.

Incertidumbre de la predicción e intervalos de predicción

En cualquier problema de estimación, es una buena práctica proporcionar una medida de la incertidumbre de esa estimación, y la predicción no es una excepción. Una medida de la incertidumbre de una predic-

ción es la raíz del error cuadrático medio de predicción. Bajo el supuesto adicional de que los errores u_t se distribuyen normalmente, la RECM se puede utilizar para construir un intervalo de predicción, es decir, un intervalo que contenga el valor futuro de la variable con una cierta probabilidad.

Incertidumbre de la predicción. El error de predicción consta de dos componentes: la incertidumbre derivada de la estimación de los coeficientes de la regresión y la incertidumbre asociada con el valor desconocido futuro de u_t . Para las regresiones con pocos coeficientes y muchas observaciones, la incertidumbre derivada del u_t futuro puede ser mucho mayor que la incertidumbre asociada a la estimación de los parámetros. Sin embargo, en general, ambas fuentes de incertidumbre son importantes, por lo que se desarrolla ahora una expresión para la RECM que incorpora estas dos fuentes de incertidumbre.

Por simplicidad de notación, consideremos las predicciones de Y_{T+1} basadas en un modelo ARD(1,1) con un único predictor, es decir, $Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_1 X_{t-1} + u_t$, y supongamos que u_t es homocedástico. La predicción es $\hat{Y}_{T+1|T} = \hat{\beta}_0 + \hat{\beta}_1 Y_T + \hat{\delta}_1 X_T$, y el error de predicción es

$$Y_{T+1} - \hat{Y}_{T+1|T} = y_{T+1} - [(\hat{\beta}_0 - \beta_0) + (\hat{\beta}_1 - \beta_1)Y_T + (\hat{\delta}_1 - \delta_1)X_T]. \quad (14.21)$$

Debido a que u_{T+1} presenta una media condicional igual a cero y es homocedástico, u_{T+1} tiene una varianza σ_u^2 y no está correlacionado con la última expresión entre corchetes de la Ecuación (14.21). Por tanto, el error cuadrático medio de la predicción (ECMP) es

$$\begin{aligned} \text{ECMP} &= E[(Y_{T+1} - \hat{Y}_{T+1|T})^2] \\ &= \sigma_u^2 + \text{var}[(\hat{\beta}_0 - \beta_0) + (\hat{\beta}_1 - \beta_1)Y_T + (\hat{\delta}_1 - \delta_1)X_T], \end{aligned} \quad (14.22)$$

y la RECM es la raíz cuadrada del ECMP.

La estimación del ECMP implica la estimación de las dos partes de la Ecuación (14.22). El primer término, σ_u^2 se puede estimar mediante el cuadrado del error estándar de la regresión, tal y como se estableció en la Sección 14.3. El segundo término requiere la estimación de la varianza de una media ponderada de los coeficientes de regresión, y los métodos para hacerlo se discutieron en la Sección 8.1 [véase la discusión al respecto de la Ecuación (8.7)].

Un método alternativo para la estimación del ECMP consiste en utilizar la varianza de la predicción pseudo-fuera de la muestra, procedimiento descrito en la Sección 14.7.

Intervalos de predicción. Un intervalo de predicción es como un intervalo de confianza, excepto por el hecho de que se refiere a una predicción. Es decir, un **intervalo de predicción** del 95 % es un intervalo que contiene el valor futuro de la serie en el 95 % de las realizaciones repetidas.

Una diferencia importante entre un intervalo de predicción y un intervalo de confianza es que la fórmula habitual para un intervalo de confianza al 95 % (el estimador ± 1.96 errores estándar) está justificada por el teorema central del límite y por lo tanto es válida para una amplia gama de distribuciones del término de error. Por el contrario, debido a que el error de predicción de la Ecuación (14.21) incluye el valor futuro del error u_{T+1} , para calcular un intervalo de predicción se requiere o bien la estimación de la distribución del término de error, o bien la formulación de algunas hipótesis adicionales acerca de la distribución.

En la práctica, resulta conveniente suponer que u_{T+1} está normalmente distribuido. Si es así, la Ecuación (14.21) y el teorema central del límite aplicado a $\hat{\beta}_0$, $\hat{\beta}_1$ y $\hat{\delta}_1$ implican que el error de predicción es la suma de dos términos independientes, y normalmente distribuidos, por lo que el error de predicción se distribuye normalmente con varianza igual al ECMP. De ello se desprende que un intervalo de confianza al 95 % está dado por $\hat{Y}_{T+1|T} \pm 1.96ES(Y_{T+1} - \hat{Y}_{T+1|T})$. Donde $ES(Y_{T+1} - \hat{Y}_{T+1|T})$ es un estimador de la RECM.

Esta discusión se ha centrado en el caso en el que el término de error, u_{T+1} , es homocedástico. Si por el contrario, u_{T+1} es heterocedástico, entonces resulta necesario desarrollar un modelo para la heterocedasticidad para que el término σ_u^2 de la Ecuación (14.22) pueda estimarse, dados los valores más recientes de Y y X , y los métodos para la modelización de esta heterocedasticidad condicional se presentan en la Sección 16.5.

Debido a la incertidumbre acerca de los sucesos futuros —es decir, la incertidumbre acerca de u_{T+1} — los intervalos de predicción al 95 % pueden ser tan amplios que pueden llegar a tener una utilidad limitada en la toma de decisiones. Por eso, los expertos en previsión económica, a menudo presentan intervalos de predicción más estrechos que el 95 %, por ejemplo, un intervalo de predicción de un error estándar (que es un intervalo de predicción al 68 % si los errores se distribuyen normalmente). Por otra parte, algunos expertos en predicción económica presentan varios intervalos de predicción, tal como lo hacen los economistas del Banco de Inglaterra cuando publican sus previsiones de inflación (véase «El río de sangre» que se muestra más abajo).

El río de sangre

Como parte de los esfuerzos realizados para informar al público acerca de sus decisiones de política monetaria, el Banco de Inglaterra publica regularmente predicciones de inflación. Esas predicciones combinan los resultados obtenidos mediante los modelos econométricos seguidos por los economistas profesionales del banco, con la opinión experta de los funcionarios veteranos del banco y el Comité de Política Monetaria. Los pronósticos se presentan en forma de conjunto de intervalos de predicción diseñados para reflejar lo que estos economistas consideran que es el rango de evolución probable que la inflación podría tomar. En su *Informe sobre inflación*, el banco imprime estos rangos en color rojo, reservando el rojo más oscuro para la banda central. Aunque el banco se refiere a esto de forma prosaica como «gráfico de abanico», la prensa ha denominado estos sombreados de tonalidades rojas como «río de sangre».

El río de sangre para noviembre de 2009 es el que se muestra en la Figura 14.4 (en esta figura la sangre es de color gris, no rojo por lo que tendrá que usarse la imaginación). Este gráfico muestra que, en noviembre de 2009, los economistas del banco esperaban que la tasa de inflación aumentase bruscamente hasta cerca del 3 % a principios de 2010, cayera aproximadamente hasta el 1 % a finales de 2010, y luego regresase a un aumento sostenido del 2 % durante 2012. No obstante, los economistas manifestaban una considerable incertidumbre acerca de la predicción. Citaban el aumento en el VAT¹ (impuesto sobre las ventas) como un factor importante del aumento de la inflación en el corto plazo y analizaban la incertidumbre asociada con la respuesta de la inflación a la ralentización de la economía y el ritmo y la fortaleza de la recuperación económica como fuentes importantes de incertidumbre inflacionaria. Como resultado, su pronóstico para un horizonte cercano estuvo muy cerca de la inflación real: la inflación en el segundo trimestre de 2010 fue del 3,5 %.


El Banco de Inglaterra ha sido pionero en el movimiento hacia una mayor apertura de los bancos centrales, y de la misma forma, otros bancos centrales publican ahora las predicciones de inflación. Las decisiones tomadas por los gestores de la política monetaria son difíciles y afectan a las vidas —y bille-

teras— de muchos de sus conciudadanos. En una democracia en la era de la información, razonan los economistas del Banco de Inglaterra, es particularmente importante que los ciudadanos entiendan las perspectivas económicas del banco y el razonamiento que subyace tras sus difíciles decisiones.

Para ver el río de sangre en su color rojo original, visite la página web del Banco de Inglaterra www.bankofengland.co.uk. Para obtener más información sobre la elaboración de predicciones de inflación por parte del Banco de Inglaterra, véase Clements (2004).

¹ N. del T.: Correspondiente al IVA.

FIGURA 14.4 El río de sangre



14.5 Selección de la longitud de los retardos mediante criterios de información

Las regresiones estimadas sobre la inflación de las Secciones 14.3 y 14.4 presentan uno o cuatro retardos de las variables predictoras. Un retardo tiene algún sentido, pero ¿por qué cuatro? De manera más general, ¿cuántos retardos se deben incluir en una regresión de series temporales? En esta sección se analizan los métodos estadísticos que se utilizan para elegir el número de retardos, en primer lugar en una autorregresión y luego, en un modelo de regresión de series temporales con varios predictores.

Determinación del orden de una autorregresión

En la práctica, en la elección del orden de una autorregresión, p , resulta necesario sopesar el beneficio marginal de incluir más retardos con el coste marginal de la incertidumbre adicional de la estimación. Por un lado, si el orden de una autorregresión estimada es demasiado bajo, se omite información potencialmente valiosa que está contenida en los valores retardados más distantes. Por otro lado, si el orden es demasiado elevado, se estiman más coeficientes que los necesarios, lo que a su vez introduce errores de estimación adicionales en las predicciones.

El método del estadístico F . Un método para la elección de p consiste en comenzar con un modelo con muchos retardos y llevar a cabo los contrastes de hipótesis sobre el último retardo. Por ejemplo, podría comenzarse por estimar un AR(6) y contrastar si el coeficiente del sexto retardo es significativo al nivel del 5 %; si no es así, se deja de lado y se estima un AR(5), contrastando el coeficiente del retardo quinto, etc. El inconveniente de este método es que va a dar lugar a un modelo demasiado grande, al menos algunas de las veces: incluso si el verdadero orden del AR es cinco, por lo que, por tanto, el coeficiente del sexto será igual a cero, un contraste al 5 % utilizando el estadístico t rechazará incorrectamente esta hipótesis nula el 5 % de las veces en cada uno de los intentos. Por tanto, cuando el verdadero valor de p es igual a cinco, este método estimará que p es igual a seis el 5 % de las veces.

El BIC. Una manera de sortear este problema es estimar p , mediante la minimización de un «criterio de información». Uno de estos criterios de información es el **criterio de información de Bayes (BIC)**, denominado asimismo *criterio de información Schwarz (SIC)*, que es

$$\text{BIC}(p) = \ln \left[\frac{SR(p)}{T} \right] + (p + 1) \frac{\ln(T)}{T}, \quad (14.23)$$

donde $SR(p)$ es la suma de los cuadrados de los residuos del modelo AR(p) estimado. El estimador BIC de p , $\hat{p}$, es el valor que minimiza $\text{BIC}(p)$ entre las opciones posibles $p = 0, 1, \dots, p_{\text{máx}}$, donde $p_{\text{máx}}$ es el mayor valor de p considerado y $p = 0$ corresponde al modelo que solamente contiene el término independiente.

La fórmula para el BIC puede parecer un poco misteriosa al principio, pero posee cierto encanto intuitivo. Consideremos el primer término de la Ecuación (14.23). Debido a que los coeficientes de regresión están estimados por MCO, la suma de los cuadrados de los residuos necesariamente disminuye (o al menos no aumenta) cuando se agrega un retardo. Por contra, el segundo término es el número de coeficientes de regresión estimados (el número de retardos, p , más uno para el término independiente) multiplicado por el factor $\ln(T)/T$. Este segundo término aumenta cuando se añade un retardo. El BIC sopesa estas dos fuerzas, por lo que el número de retardos que minimiza el BIC es un estimador consistente de la verdadera longitud de los retardos. Las matemáticas de este argumento aparecen en el Apéndice 14.5.

A modo de ejemplo, consideremos la estimación del orden del modelo AR para una autorregresión de la variación en la tasa de inflación. Las distintas etapas para el cálculo del BIC se llevan a cabo en la Tabla 14.4 para modelos autorregresivos con un orden máximo de seis ($p_{\text{máx}} = 6$). Por ejemplo, para el modelo AR(1) de la Ecuación (14.7), $SR(1)/T = 2,737$, por lo que $\ln[SR(1)/T] = 1,007$. Debido a que $T = 172$ (43 años, cuatro trimestres por año), $\ln(T)/T = 0,030$ y $(p + 1)\ln(T)/T = 2 \times 0,030 = 0,060$. Por lo tanto $BIC(1) = 1,007 + 0,060 = 1,067$.

El BIC más pequeño se alcanza cuando $p = 2$ en la Tabla 14.4. Por tanto, la estimación BIC para la longitud del retardo es 2. Como se puede observar en la Tabla 14.4, al aumentar el número de retardos aumenta el R^2 y disminuye la SR. El aumento de R^2 es grande cuando se pasa de uno a dos retardos, más pequeño de dos a tres, y bastante más pequeño de tres a cuatro. El BIC ayuda a decidir exactamente cuánto debe ser el aumento de R^2 para justificar la inclusión del retardo adicional.

El AIC. El BIC no es el único criterio de información; otro es el **criterio de información de Akaike (AIC)**:

$$AIC(p) = \ln \left[\frac{SR(p)}{T} \right] + (p + 1) \frac{2}{T} \quad (14.24)$$

La diferencia entre el criterio AIC y el BIC es que el término « $\ln(T)$ » del BIC se sustituye por «2» en el AIC, por lo que el segundo término del AIC es menor. Por ejemplo, para las 172 observaciones utilizadas para estimar los modelos autorregresivos para la inflación, $\ln(T) = \ln(172) = 5,15$, por lo que el segundo término del BIC es más del doble de grande que el término en el AIC. Por tanto, se necesita una disminución menor de la SR en el AIC para justificar la inclusión de otro retardo. Como cuestión teórica, el segundo término del AIC no es lo suficientemente grande como para asegurar que la longitud de los retardos se haya elegido correctamente, incluso en muestras grandes, por lo que el estimador AIC de p no es consistente. Tal y como se analiza en el Apéndice 14.5, en muestras grandes el criterio AIC sobrestima p con una probabilidad distinta de cero.

A pesar de este defecto teórico, el criterio AIC es utilizado habitualmente en la práctica. Si puede existir alguna preocupación acerca de que el BIC pueda dar lugar a un modelo con muy pocos retardos, el AIC ofrece una alternativa razonable.

Una nota acerca del cálculo de los criterios de información. Se evalúa mejor la bondad del ajuste a los datos de dos regresiones estimadas cuando ambas se calculan utilizando el mismo conjunto de datos. Debido a que el BIC y AIC son métodos formales para realizar esta comparación, los modelos autorregresivos en consideración deberían estimarse utilizando las mismas observaciones. Por ejemplo, en la Tabla 14.4

TABLA 14.4 El criterio de información de Bayes (BIC) y el R^2 para modelos autorregresivos de inflación en EE.UU., 1962-2004

p	$SR(p)/T$	$\ln[SR(p)/T]$	$(p+1)\ln(T)/T$	$BIC(p)$	R^2
0	2,900	1,065	0,030	1,095	0,000
1	2,737	1,007	0,60	1,067	0,056
2	2,375	0,865	0,090	0,955	0,181
3	2,311	0,838	0,120	0,957	0,203
4	2,309	0,837	0,150	0,986	0,204
5	2,308	0,836	0,180	1,016	0,204
6	2,308	0,836	0,209	1,046	0,204

todas las regresiones se estimaron a partir de los datos desde 1962:I hasta 2004:IV, para un total de 172 observaciones. Debido a que los modelos autorregresivos incluyen retardos de la variación de la inflación, esto significa que los valores de la variación de la inflación anteriores (los valores anteriores a 1962:I) se utilizaron como variables explicativas de las observaciones preliminares. Dicho de otro modo, cada una de las regresiones examinadas en la Tabla 14.4, incluyen observaciones sobre $\Delta Inf_t, \Delta Inf_{t-2}, \dots, \Delta Inf_{t-p}$, para $t = 1962:I, \dots, 2004:IV$, lo que corresponde a 172 observaciones sobre la variable dependiente y las variables explicativas, por lo que $T = 172$ en las Ecuaciones (14.23) y (14.24).

Selección de la longitud de los retardos en una regresión de series temporales con varios predictores

El conflicto entre dos magnitudes que implica la selección de la longitud de los retardos en el modelo general de regresión de series temporales con varios predictores [Ecuación (14.20)] es similar al del modelo autorregresivo: utilizar demasiado pocos retardos puede hacer disminuir la precisión de las predicciones debido a que se pierde información valiosa, pero la adición de retardos aumenta la incertidumbre de la estimación. La elección de los retardos debe equilibrar las ventajas de utilizar información adicional con el coste de estimación de los coeficientes adicionales.

El método del estadístico F . Al igual que en el modelo autorregresivo univariante, una forma de determinar el número de retardos a incluir es mediante la utilización del estadístico F para el contraste de la hipótesis conjunta de que algún conjunto de coeficientes es igual a cero. Por ejemplo, en el análisis de la Ecuación (14.17), se contrastaba la hipótesis de que los coeficientes desde el segundo al cuarto retardo de la tasa de desempleo eran iguales a cero frente a la alternativa de que eran distintos de cero; esta hipótesis fue rechazada al nivel de significación del 1 %, lo que apoyaba la especificación con mayor longitud de retardos. Si el número de modelos que se comparan es pequeño, entonces este método del estadístico F resulta fácil de utilizar. Sin embargo, en general, el método del estadístico F puede dar lugar a modelos que sean demasiado grandes, en el sentido de que el verdadero orden de los retardos se sobrestime.

Criterios de información. Al igual que en un modelo autorregresivo, el BIC y el AIC pueden utilizarse para estimar el número de retardos y de variables del modelo de regresión de series temporales con varios predictores. Si el modelo de regresión tiene K coeficientes (incluyendo el término independiente), El BIC es

$$\text{BIC}(K) = \ln \left[\frac{SR(K)}{T} \right] + K \frac{\ln(T)}{T} \quad (14.25)$$

El AIC se define del mismo modo, pero sustituyendo el término $\ln(T)$ de la Ecuación (14.25) por el término 2. Se puede evaluar el BIC (o el AIC) para cada modelo candidato, y el modelo preferido será el del valor del BIC (o del AIC) más bajo, en base al criterio de información.

Existen dos consideraciones de orden práctico importantes a la hora de utilizar un criterio de información para calcular la longitud de los retardos. En primer lugar, como en el caso del modelo autorregresivo, deben estimarse todos los modelos candidatos a lo largo de la misma muestra; en la notación de la Ecuación (14.25), el número de observaciones utilizadas para estimar el modelo, T , debe ser el mismo para todos los modelos. En segundo lugar, cuando hay varios predictores, este método resulta exigente desde el punto de vista computacional, debido a que requiere el cálculo de muchos modelos diferentes (muchas combinaciones de los parámetros de los retardos). En la práctica, conviene utilizar un atajo que consiste en exigir que todas las variables explicativas tengan el mismo número de retardos, es decir, exigir que $p = q_1 = \dots = q_k$, por lo que solamente es necesario comparar $p_{\text{máx}} + 1$ modelos (lo que corresponde a $p = 0, 1, \dots, p_{\text{máx}}$).

14.6 Ausencia de estacionariedad I: tendencias

En el Concepto clave 14.6, se suponía que la variable dependiente y los regresores eran estacionarios. Si este no es el caso, es decir, si la variable dependiente y/o los regresores no son estacionarios, los contrastes de hipótesis, los intervalos de confianza y las predicciones habituales pueden resultar poco fiables. El problema exacto ocasionado por la ausencia de estacionariedad, y la solución a este mismo problema, depende de la naturaleza de la ausencia de estacionariedad.

En esta sección y en la siguiente, se examinan dos de los más importantes tipos de ausencia de estacionariedad en los datos de series temporales económicas: las tendencias y los cambios estructurales. En cada una de las secciones, se describe en primer lugar la naturaleza de la no estacionariedad y más tarde se discuten las consecuencias que origina sobre la regresión de series de temporales, el hecho de ignorar la presencia de este tipo de no estacionariedad. A continuación se presentan los contrastes de detección de no estacionariedad y se discuten los remedios o las soluciones a los problemas causados por ese tipo concreto de no estacionariedad. Comenzamos por analizar las tendencias

¿Qué es una tendencia?

Una **tendencia** es un movimiento persistente a largo plazo de una variable en el tiempo. Una variable de series temporales fluctúa en torno a su tendencia.

La observación de la Figura 14.1a sugiere que la tasa de inflación en los EE.UU. presenta una tendencia que consiste en una propensión general creciente hasta 1982 y una propensión descendente a partir de entonces. Las series de las Figuras 14.2a, b, c, asimismo presentan tendencias, pero sus tendencias son muy diferentes. La tendencia del tipo de interés de los fondos federales en EE.UU. es similar a la tendencia de la tasa de inflación de los EE.UU. El tipo de cambio \$/£ presenta claramente una prolongada tendencia a la baja tras el colapso del sistema de tipos de cambio fijos en 1972. El logaritmo del PIB de Japón presenta una tendencia complicada: crecimiento rápido al principio, más tarde crecimiento moderado, y finalmente crecimiento lento.

Tendencias determinísticas y estocásticas. Existe la posibilidad de observar dos tipos de tendencias en datos de series temporales: determinísticas y estocásticas. Una **tendencia determinística** es una función no aleatoria del tiempo. Por ejemplo, una tendencia determinística puede ser lineal en el tiempo; si la inflación presenta una tendencia determinística lineal, de forma que aumenta en 0.1 puntos porcentuales por trimestre, esta tendencia podría escribirse como $0.1t$, donde t se mide en periodos. Por el contrario, una **tendencia estocástica** es aleatoria y varía en el tiempo. Por ejemplo, una tendencia estocástica en la inflación podría presentar un periodo prolongado de crecimiento seguido por un periodo prolongado de decrecimiento, como el de la tendencia que presenta la inflación en la Figura 14.1.

Al igual que muchos económetras, creemos que resulta más apropiado modelizar las series temporales económicas de forma que presenten tendencias estocásticas en lugar de tendencias determinísticas. La economía resulta complicada. Resulta duro conciliar la predictibilidad que implica una tendencia determinística con las complicaciones y sorpresas que afrontan año tras año los trabajadores, las empresas y los gobiernos. Por ejemplo, aunque la inflación en EE.UU. subiera durante la década de 1970, ni estaba destinada a un aumento eterno ni estaba destinada a volver a disminuir. Por el contrario, el lento ascenso de la inflación en la actualidad se entiende que se produjo a causa de la mala suerte y los errores de política monetaria, y su control fue en gran parte una consecuencia de las difíciles decisiones tomadas por la Junta de Gobernadores de la Reserva Federal. Del mismo modo, el tipo de cambio \$/£ presentaba una tendencia bajista desde 1972 hasta 1985 y, posteriormente ascendente, pero estos movimientos fueron asimismo las consecuencias de fuerzas económicas complejas; debido a que estas fuerzas cambian de manera impredecible, se interpreta que estas tendencias poseen una componente muy imprevisible, o aleatoria.

Por estas razones, nuestro tratamiento de las tendencias en series temporales económicas se centra en las tendencias estocásticas, más que en las tendencias determinísticas, y cuando nos refiramos a las «tenden-

cias» en datos de series temporales nos referimos a las tendencias estocásticas a menos que explícitamente se diga otra cosa. Esta sección presenta el modelo más sencillo para una tendencia estocástica, el modelo de paseo aleatorio; en la Sección 16.3 se analizan otros modelos de tendencias.

El modelo de paseo aleatorio para la tendencia. El modelo más sencillo de una variable con tendencia estocástica es el paseo aleatorio. Se dice que una serie temporal Y_t sigue un **paseo aleatorio** si la variación de Y_t es i.i.d., es decir, si

$$Y_t = Y_{t-1} + u_t, \quad (14.26)$$

donde u_t es i.i.d. No obstante, utilizaremos el término *paseo aleatorio* en un sentido más general para referirnos a una serie temporal que sigue la Ecuación (14.26), donde u_t presenta una media condicional igual a cero; es decir, $E(u_t|Y_{t-1}, Y_{t-2}, \dots) = 0$.

La idea básica de un paseo aleatorio es que el valor de la serie mañana es su valor hoy, más una variación impredecible: debido a que la senda seguida por Y_t consiste en «pasos» aleatorios u_t , esa senda es un «paseo aleatorio». La media condicional de Y_t basada en los datos hasta el periodo $t - 1$ es Y_{t-1} ; es decir, debido a que $E(u_t|Y_{t-1}, Y_{t-2}, \dots) = 0$, entonces $E(Y_t|Y_{t-1}, Y_{t-2}, \dots) = Y_{t-1}$. En otras palabras, si Y_{t-1} sigue un proceso de paseo aleatorio, entonces la mejor predicción del valor de mañana es su valor en la actualidad.

Algunas series, como el logaritmo del PIB japonés de la Figura 14.2c, presentan una tendencia obviamente creciente, en cuyo caso el mejor pronóstico de la serie debe incluir un ajuste por el aumento tendencial de la serie. Este ajuste lleva a una extensión del modelo de paseo aleatorio para incluir un movimiento tendencial, o «deriva», en una dirección u otra. Esta extensión se conoce como **paseo aleatorio con deriva**:

$$Y_t = \beta_0 + Y_{t-1} + u_t, \quad (14.27)$$

donde $E(u_t|Y_{t-1}, Y_{t-2}, \dots) = 0$ y β_0 es la «deriva» del paseo aleatorio. Si β_0 es positivo, entonces Y_t aumenta en promedio. En el modelo de paseo aleatorio con deriva, la mejor predicción de la serie mañana es el valor de la serie hoy, más la deriva β_0 .

El modelo de paseo aleatorio (con deriva en su caso) es sencillo y versátil, y es el principal modelo para las tendencias utilizado en este libro.

Un paseo aleatorio es no estacionario. Si Y_t sigue un paseo aleatorio, entonces no es estacionaria: la varianza de un paseo aleatorio aumenta en el tiempo, por lo que la distribución de Y_t cambia en el tiempo. Una forma de comprobarlo es reconocer que, debido a que u_t está incorrelacionado con Y_{t-1} en la Ecuación (14.26), $\text{var}(Y_t) = \text{var}(Y_{t-1}) + \text{var}(u_t)$; para que Y_t sea estacionaria $\text{var}(Y_t)$ no puede depender del tiempo, por lo que, en particular debe cumplirse $\text{var}(Y_t) = \text{var}(Y_{t-1})$, pero esto solo puede ocurrir si $\text{var}(u_t) = 0$. Otra forma de comprobarlo es imaginar que Y_t comienza en cero; es decir, $Y_0 = 0$. Por lo tanto $Y_1 = u_1$, y $Y_2 = u_1 + u_2$, y así sucesivamente de manera que $Y_t = u_1 + u_2 + \dots + u_t$. Debido a que u_t está serialmente incorrelacionado, $\text{var}(Y_t) = \text{var}(u_1 + u_2 + \dots + u_t) = t\sigma_u^2$. Por tanto, la varianza de Y_t depende de t ; de hecho, aumenta a medida que t aumenta. Debido a que la varianza de Y_t depende de t , su distribución depende de t , es decir, es no estacionaria.

Debido a que la varianza de un paseo aleatorio aumenta sin límite, sus autocorrelaciones *poblacionales* no están definidas (la primera autocovarianza y la varianza son infinitas, y el cociente entre las dos no está bien definido). Sin embargo, una característica de un paseo aleatorio es que sus autocorrelaciones *muestrales* suelen ser próximas a 1; de hecho, la j -ésima autocorrelación muestral de un paseo aleatorio converge a 1 en probabilidad.

Tendencias estocásticas, modelos autorregresivos, y raíz unitaria. El modelo de paseo aleatorio es un caso particular del modelo AR(1) [Ecuación (14.8)] en el que $\beta_1 = 1$. En otras palabras, si Y_t sigue un proceso AR(1) con $\beta_1 = 1$, entonces Y_t presenta una tendencia estocástica y es no estacionaria. Sin embargo, si $|\beta_1| < 1$, y u_t es estacionario, entonces la distribución conjunta de Y_t y sus retardos no depende de t (un resultado que se demuestra en el Apéndice 14.2), por lo que Y_t es estacionaria.

La condición análoga para que un proceso AR(p) sea estacionario es más complicada que la condición $|\beta_1| < 1$ para un AR(1). Su enunciado formal implica que las raíces del polinomio, $1 - \beta_1 z - \beta_2 z^2 -$

$-\beta_3 z^3 - \dots - \beta_p z^p$. (Las raíces de este polinomio son los valores de z que satisfacen $1 - \beta_1 z - \beta_2 z^2 - \dots - \beta_p z^p = 0$). Para que un proceso $AR(p)$ sea estacionario, todas las raíces de este polinomio deben ser mayores que 1 en valor absoluto. En el caso particular de un proceso $AR(1)$, la raíz es el valor de z que resuelve la ecuación $1 - \beta_1 z = 0$, por lo que su raíz es $z = 1/\beta_1$. Por lo que la afirmación de que la raíz debe ser mayor que 1 en valor absoluto equivale a que $\beta_1 < 1$.

Si un proceso $AR(p)$ tiene una raíz que es igual a 1, se dice que la serie presenta una *raíz unitaria autorregresiva* o, más sencillamente, una **raíz unitaria**. Si Y_t presenta una raíz unitaria, entonces presenta una tendencia estocástica. Si Y_t es estacionaria (y por lo tanto no tiene una raíz unitaria), no presenta una tendencia estocástica. Por esta razón, utilizaremos los términos *tendencia estocástica* y *raíz unitaria* de manera intercambiable.

Problemas ocasionados por las tendencias estocásticas

Si un regresor presenta una tendencia estocástica (tiene una raíz unitaria), entonces el estimador MCO de su coeficiente y su estadístico t MCO pueden presentar una distribución no estándar (es decir, distinta de la normal), incluso en muestras grandes. Se analizan tres aspectos específicos de este problema: (1) el estimador del coeficiente autorregresivo en un modelo $AR(1)$ está sesgado hacia 0 si su verdadero valor es 1, (2) el estadístico t de un regresor con una tendencia estocástica puede tener una distribución distinta de la normal, incluso en muestras grandes; y (3) un ejemplo extremo de los riesgos que plantean las tendencias estocásticas es que dos series que son independientes parecerá, con alta probabilidad, que están relacionadas, de forma engañosa, si las dos presentan tendencias estocásticas, una situación conocida como regresión espuria.

Problema #1: coeficientes autorregresivos que están sesgados hacia cero. Supongamos que Y_t sigue el paseo aleatorio de la Ecuación (14.26), pero que esto es desconocido por el económetra, que en su lugar estima el modelo $AR(1)$ de la Ecuación (14.8). Debido a que Y_t es no estacionaria, los supuestos de mínimos cuadrados para la regresión de series temporales del Concepto clave 14.6 no se cumplen, por lo que, con carácter general, no puede confiarse en que los estimadores y los estadísticos de contraste presenten sus distribuciones normales habituales para grandes muestras. De hecho, en este ejemplo el estimador MCO del coeficiente autorregresivo, $\hat{\beta}_1$, es consistente, pero tiene una distribución distinta de la normal, incluso en muestras grandes: la distribución asintótica de $\hat{\beta}_1$ se desplaza hacia cero. La esperanza de $\hat{\beta}_1$ es aproximadamente $E(\hat{\beta}_1) = 1 - 5,3/T$. Esto se traduce en un gran sesgo para los tamaños muestrales que suelen encontrarse en las aplicaciones económicas. Por ejemplo, 20 años de datos trimestrales contienen 80 observaciones, en cuyo caso el valor esperado de $\hat{\beta}_1$ es $E(\hat{\beta}_1) = 1 - 5,3/80 = 0,934$. Por otra parte, esta distribución presenta un cola izquierda larga: el percentil 5 de $\hat{\beta}_1$ es aproximadamente $1 - 14,1/T$, lo que, debido a que $T = 80$, corresponde a 0,824, por lo que el 5 % de las veces $\hat{\beta}_1 < 0,824$.

Una consecuencia de este sesgo hacia cero es que si Y_t sigue un paseo aleatorio, entonces las predicciones basadas en el modelo $AR(1)$ pueden comportarse de modo sustancialmente peor que las basadas en el modelo de paseo aleatorio, que impone el verdadero valor $\beta_1 = 1$. Esta conclusión es aplicable asimismo a modelos autorregresivos de orden superior, en los que hay ganancias en las predicciones imponiendo una raíz unitaria (es decir, estimando la autorregresión en primeras diferencias en lugar de en niveles), cuando en realidad la serie contiene una raíz unitaria.

Problema #2: distribuciones no normales del estadístico t . Si un regresor presenta una tendencia estocástica, entonces su estadístico t MCO habitual puede presentar, bajo la hipótesis nula, una distribución distinta de la normal, incluso en muestras grandes. Esta distribución no normal significa que no son válidos los intervalos de confianza habituales y los contrastes de hipótesis no pueden llevarse a cabo como de costumbre. En general, la distribución de este estadístico t no estará tabulada previamente debido a que la distribución depende de la relación entre el regresor en cuestión y el resto de los regresores. Un ejemplo importante de este problema aparece en las regresiones que tratan de predecir las rentabilidades de las acciones mediante regresores que podrían presentar tendencias estocásticas (véase el recuadro de la Sección 14.7, «¿Se puede batir al mercado? Parte II»).

Un caso importante en el que *es* posible tabular la distribución del estadístico t cuando el regresor tiene una tendencia estocástica es en el contexto de un modelo autorregresivo con una raíz unitaria. Volveremos a este caso particular cuando abordemos el problema de comprobar si una serie temporal contiene una tendencia estocástica.

Problema #3: regresión espuria. Las tendencias estocásticas pueden originar que dos series temporales parezcan estar relacionadas cuando en realidad no lo están, un problema que se denomina **regresión espuria**.

Por ejemplo, la inflación en EE.UU. aumentó de forma sostenida desde mediados de la década de 1960 hasta los primeros años de la década de 1980, y al mismo tiempo el PIB japonés (representado en logaritmos en la Figura 14.2c) aumentó de forma sostenida. Estas dos tendencias conspiran para dar lugar a una regresión que parece ser «significativa» utilizando las medidas convencionales. Estimada por MCO utilizando los datos desde 1965 a 1981, esta regresión es

$$\widehat{\text{InflaciónEE.UU.}_t} = -37,78 + 3,83 \times \ln(\text{PIBJaponés}_t), \bar{R}^2 = 0,56. \quad (14.28)$$

(3,99) (0,36)

El estadístico t del coeficiente de la pendiente es mayor que 10, lo que para los estándares habituales indica una fuerte relación positiva entre las dos series, y el $\bar{R}^2$ es elevado. Sin embargo, la realización de esta regresión con los datos desde 1982 a 2004 proporciona los siguientes resultados

$$\widehat{\text{InflaciónEE.UU.}_t} = 31,20 + 2,17 \times \ln(\text{PIBJaponés}_t), \bar{R}^2 = 0,08. \quad (14.29)$$

(10,41) (0,80)

Las regresiones de las Ecuaciones (14.28) y (14.29) no podrían ser más diferentes. Interpretadas en términos literales, la Ecuación (14.28) indica una fuerte relación positiva, mientras que la Ecuación (14.29) indica una débil relación negativa, pero en apariencia estadísticamente significativa.

La razón de estos resultados contradictorios es que ambas series presentan tendencias estocásticas. Estas tendencias se alinearon desde 1965 hasta 1981, pero no hubo alineamiento en el periodo que va desde 1982 hasta 2004. No existe, de hecho, ninguna razón de peso, ya sea desde el punto de vista económico o político, para creer que las tendencias de estas dos series estén relacionadas. En resumen, estas regresiones son espurias.

Las regresiones de las Ecuaciones (14.28) y (14.29) ilustran de forma empírica la cuestión teórica de que MCO puede resultar engañoso cuando las series contienen tendencias estocásticas (véase el Ejercicio 14.6 para una simulación por ordenador que demuestra este resultado). Un caso particular en el que algunos métodos basados en la regresión *resultan* fiables es cuando la componente de tendencia de las dos series es la misma, es decir, cuando las series contienen una tendencia estocástica *común*, si es así, se dice que las series están cointegradas. Los métodos econométricos para la detección y el análisis de series temporales económicas cointegradas se discuten en la Sección 16.4.

Detección de tendencias estocásticas: contraste de raíz unitaria AR

Las tendencias en los datos de series temporales pueden detectarse mediante métodos formales e informales. Los métodos informales incluyen la inspección de los gráficos de los datos de series temporales y el cálculo de los coeficientes de autocorrelación, tal y como se llevó a cabo en la Sección 14.2. Debido a que el primer coeficiente de autocorrelación estará cerca de 1 si la serie tiene una tendencia estocástica, al menos en muestras grandes, un primer coeficiente de autocorrelación pequeño combinado con un gráfico de la serie temporal que aparentemente no tenga tendencia sugiere que la serie no tiene tendencia. Sin embargo, si queda alguna duda, existen procesos estadísticos formales que pueden utilizarse para contrastar la hipótesis de que existe una tendencia estocástica en la serie frente a la alternativa de que no existe ninguna tendencia.

En esta sección, se utiliza el contraste de Dickey-Fuller (denominado así por sus inventores David Dickey y Wayne Fuller, 1979) para contrastar la presencia de una tendencia estocástica. A pesar de que el

contraste de Dickey-Fuller no es el único contraste de presencia de una tendencia estocástica (se discute otro contraste en la Sección 16.3), es el contraste más utilizado en la práctica y es uno de los más fiables.

El contraste de Dickey-Fuller en el modelo AR(1). El punto de partida del **contraste de Dickey-Fuller** es el modelo autorregresivo. Como se señaló anteriormente, el paseo aleatorio de la Ecuación (14.27) es un caso particular del modelo AR(1) con $\beta_1 = 1$. Si $\beta_1 = 1$, Y_t es no estacionaria y contiene una tendencia (estocástica). Por tanto, en el modelo AR(1), la hipótesis de que Y_t tiene una tendencia puede ser contrastada mediante el contraste

$$H_0: \beta_1 = 1 \text{ vs. } H_1: \beta_1 < 1 \text{ en } Y_t = \beta_0 + \beta_1 Y_{t-1} + u_t. \quad (14.30)$$

Si $\beta_1 = 1$, el AR(1) tiene una raíz autorregresiva igual a 1, por lo que la hipótesis nula en la Ecuación (14.30) es que el AR(1) tiene una raíz unitaria, y la alternativa es que es estacionario.

Este contraste resulta más fácil de llevar a la práctica mediante la estimación de una versión modificada de la Ecuación (14.30) obtenida restando Y_{t-1} de ambos lados. Sea $\delta = \beta_1 - 1$; por tanto la Ecuación (14.30) se convierte en

$$H_0: \delta = 0 \text{ vs. } H_1: \delta < 0 \text{ en } \Delta Y_t = \beta_0 + \delta Y_{t-1} + u_t. \quad (14.31)$$

El estadístico t MCO para contrastar $\delta = 0$ en la Ecuación (14.31) se denomina **estadístico de Dickey-Fuller**. La formulación de la Ecuación (14.31) resulta conveniente debido a que el *software* de regresión reporta automáticamente el estadístico t para contrastar $\delta = 0$. Téngase en cuenta que el contraste de Dickey-Fuller es unilateral, debido a que la alternativa relevante es que Y_t sea estacionaria, por lo que $\beta_1 < 1$ o, equivalentemente, $\delta < 0$. El estadístico de Dickey-Fuller se calcula utilizando errores estándar «no robustos», es decir, los errores estándar «válidos con homocedasticidad» presentados en el Apéndice 5.1 [Ecuación (5.29) para el caso de un único regresor y en la Sección 18.4 para el modelo de regresión múltiple]³.

El contraste de Dickey-Fuller en el modelo AR(p). El estadístico de Dickey-Fuller presentado en el contexto de la Ecuación (14.31) solamente es aplicable a un AR(1). Tal y como se analizó en la Sección 14.3, en algunas series el modelo AR(1) no capta toda la correlación serial de Y_t , en cuyo caso, resulta más apropiado un modelo autorregresivo de orden superior.

La extensión del contraste de Dickey-Fuller al modelo AR(p) se resume en el Concepto clave 14.8. Bajo la hipótesis nula, $\delta = 0$ y ΔY_t es un proceso AR(p) estacionario. Bajo la hipótesis alternativa, $\delta < 0$, por lo que Y_t es estacionario. Debido a que el modelo de regresión utilizado para calcular esta versión del estadístico de Dickey-Fuller se ve aumentado por los retardos de ΔY_t , el estadístico t resultante se conoce como **estadístico de Dickey-Fuller aumentado (ADF)**.

En general, la longitud del retardo p es desconocida, pero puede estimarse mediante un criterio de información aplicado a las regresiones del tipo de la Ecuación (14.32) para distintos valores de p . Los estudios del estadístico ADF sugieren que es mejor tener demasiados retardos que demasiado pocos, por lo que se recomienda la utilización del criterio de información AIC en lugar del criterio de información BIC para estimar p para el estadístico ADF⁴.

Contraste frente a la alternativa de estacionariedad en torno a una tendencia temporal determinística. Hasta el momento, el análisis ha considerado la hipótesis nula de que la serie tiene una raíz unitaria, y la hipótesis alternativa de que es estacionaria. Esta hipótesis alternativa de estacionariedad es adecuada para las series, como la tasa de inflación, que no presentan crecimiento a largo plazo. Sin embargo, otras series temporales económicas, como el PIB japonés (Figura 14.2c), muestran crecimiento a largo plazo, y para tales series la alternativa de estacionariedad sin tendencia no es apropiada. En cambio, una alternativa que se utiliza habitualmente es que las series sean estacionarias alrededor de una tendencia temporal determinística, es decir, una tendencia que sea una función determinística del tiempo.

³ Bajo la hipótesis nula de presencia de una raíz unitaria, los errores estándar «no robustos» habituales dan lugar a un estadístico t que es en realidad robusto respecto de heterocedasticidad, un resultado sorprendente y particular.

⁴ Véase Stock (1994) y Haldrup y Jansson (2006) para una revisión de los estudios de simulación de las propiedades en muestras finitas del estadístico de Dickey-Fuller y otros estadísticos de contraste de raíz unitaria.

**CONCEPTO
CLAVE****14.8****El contraste de Dickey-Fuller aumentado para raíz unitaria autorregresiva**

El contraste de Dickey-Fuller aumentado (ADF) para una raíz unitaria autorregresiva contrasta la hipótesis nula $H_0: \delta = 0$ frente a la hipótesis alternativa unilateral $H_1: \delta < 0$ en la regresión

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \gamma_1 \Delta Y_{t-1} + \gamma_2 \Delta Y_{t-2} + \cdots + \gamma_p \Delta Y_{t-p} + u_t. \quad (14.32)$$

Bajo la hipótesis nula, Y_t tiene una tendencia estocástica; bajo la hipótesis alternativa, Y_t es estacionaria. El estadístico ADF es el estadístico t MCO para contrastar $\delta = 0$ en la Ecuación (14.32).

Si en su lugar, la hipótesis alternativa es que Y_t es estacionaria en torno a una tendencia temporal lineal determinística, entonces debe añadirse esta tendencia, « t » (el número de observación), como regresor adicional, en cuyo caso la regresión de Dickey-Fuller se convierte en

$$\Delta Y_t = \beta_0 + \alpha t + \delta Y_{t-1} + \gamma_1 \Delta Y_{t-1} + \gamma_2 \Delta Y_{t-2} + \cdots + \gamma_p \Delta Y_{t-p} + u_t, \quad (14.33)$$

donde α es un coeficiente desconocido y el estadístico ADF es el estadístico t MCO para contrastar $\delta = 0$ en la Ecuación (14.33).

La longitud del retardo, p , se puede estimar utilizando el criterio BIC o AIC. Cuando $p = 0$, no se incluyen retardos de ΔY_t como regresores en las Ecuaciones (14.32) y (14.33), y el contraste ADF se simplifica al contraste de Dickey-Fuller en el modelo AR(1). El estadístico ADF *no* sigue una distribución normal, incluso en muestras grandes. Los valores críticos para el contraste ADF unilateral dependen de si el contraste está basado en la Ecuación (14.32) o en la (14.33) y se presentan en la Tabla 14.5.

Una formulación específica de esta hipótesis alternativa es que la tendencia temporal es lineal, es decir, la tendencia es una función lineal de t ; por lo tanto, la hipótesis nula es que la serie tiene una raíz unitaria, y la alternativa es que no tiene una raíz unitaria, pero tiene una tendencia temporal determinística. La regresión de Dickey-Fuller debe modificarse para contrastar la hipótesis nula de una raíz unitaria frente a la alternativa de que es estacionaria alrededor de una tendencia temporal lineal. Como se resume en la Ecuación (14.33) del Concepto clave 14.8, esto se logra añadiendo una tendencia temporal (el regresor $X_t = t$) a la regresión.

Una tendencia temporal lineal no es el único modo de especificar una tendencia temporal determinística; por ejemplo, la tendencia temporal determinística podría ser cuadrática, o podría ser lineal pero presentar cambios estructurales (es decir, ser lineal con pendientes que son distintas en dos partes de la muestra). La utilización de alternativas como estas, con tendencias determinísticas no lineales, debería estar motivada por la teoría económica. Para un estudio detallado de los contrastes de raíz unitaria frente a estacionariedad en torno a tendencias determinísticas no lineales, véase Maddala y Kim (1998, Capítulo 13).

Valores críticos para el estadístico ADF. Bajo la hipótesis nula de existencia de una raíz unitaria, el estadístico ADF *no* tiene una distribución normal, incluso en muestras grandes. Debido a que su distribución no es estándar, no pueden ser utilizados los valores críticos habituales de la distribución normal cuando se utiliza el estadístico ADF para el contraste de raíz unitaria; debe utilizarse en su lugar un conjunto particular de valores críticos, basados en la distribución del estadístico ADF bajo la hipótesis nula.

Los valores críticos para el contraste ADF se ofrecen en la Tabla 14.5. Debido a que la hipótesis alternativa de estacionariedad implica que en las Ecuaciones (14.32) y (14.33), $\delta < 0$, el contraste ADF es unilateral. Por ejemplo, si la regresión no incluye una tendencia temporal, entonces se rechaza la hipótesis de una raíz unitaria al nivel de significación del 5 % si el estadístico ADF es menor que -2.86 . Si se incluye una tendencia temporal en la regresión, el valor crítico en su lugar es -3.41 .

TABLA 14.5 Valores críticos para muestras grandes del estadístico Dickey-Fuller aumentado

Regresores determinísticos	10 %	5 %	1 %
Solamente término independiente	-2,57	-2,86	-3,43
Término independiente y tendencia temporal	-3,12	-3,41	-3,96

Los valores críticos de la Tabla 14.5 son considerablemente menores (más negativos) que los valores críticos unilaterales de $-1,28$ (al nivel del 10 %) y $-1,645$ (al 5 % de nivel) de la distribución normal estándar. La distribución no estándar del estadístico ADF es un ejemplo de cómo los estadísticos t MCO para los regresores con tendencias estocásticas pueden tener distribuciones no normales. La razón por la cual la distribución del estadístico ADF no es estándar se trata en profundidad en la Sección 16.3.

¿Presenta la inflación en EE.UU. una tendencia estocástica? Se puede contrastar la hipótesis nula de que la inflación tiene una tendencia estocástica frente a la alternativa de que es estacionaria mediante un contraste ADF para una raíz unitaria autorregresiva. La regresión ADF con cuatro retardos de Inf_t es

$$\widehat{\Delta Inf_t} = 0,51 - 0,11Inf_{t-1} - 0,19\Delta Inf_{t-1} - 0,26\Delta Inf_{t-2} + 0,20\Delta Inf_{t-3} + 0,01\Delta Inf_{t-4}. \quad (14.34)$$

(0,21) (0,04) (0,08) (0,08) (0,08) (0,08)

El estadístico t ADF es el estadístico t para el contraste de la hipótesis de que el coeficiente de la variable Inf_{t-1} es igual a cero; es decir, $t = -2,69$. A partir de la Tabla 14.5, el valor crítico al 5 % es $-2,86$. Debido a que el estadístico ADF de $-2,69$ es menos negativo que $-2,86$, el contraste no rechaza la hipótesis nula al nivel de significación del 5 %. En base a la regresión de la Ecuación (14.34), por lo tanto, no puede rechazarse (al nivel de significación del 5 %) la hipótesis nula de que la inflación tiene una raíz unitaria autorregresiva, es decir, que la inflación contiene una tendencia estocástica, frente a la alternativa de que es estacionaria.

La regresión ADF de la Ecuación (14.34) incluye cuatro retardos de la variable ΔInf_t para calcular el estadístico ADF. Cuando el número de retardos se calcula utilizando el criterio AIC, con $0 \leq p \leq 5$, sin embargo, el estimador AIC de la longitud de los retardos, es tres. Cuando se utilizan tres retardos (es decir, cuando ΔInf_{t-1} , ΔInf_{t-2} , y ΔInf_{t-3} se incluyen como regresores), el estadístico ADF es $-2,72$, que es menos negativo que $-2,86$. Por lo tanto, cuando el número de retardos en la regresión ADF se elige mediante el criterio AIC, no se rechaza la hipótesis de que la inflación contiene una tendencia estocástica al nivel de significación del 5 %.

Estos contrastes se realizaron al nivel de significación del 5 %. Sin embargo, al 10 % de nivel de significación, los contrastes rechazan la hipótesis nula de una raíz unitaria: los estadísticos ADF de $-2,69$ (cuatro retardos) y $-2,72$ (tres retardos) son más negativos que el valor crítico de $-2,57$ al 10 %. Por lo tanto los estadísticos ADF pintan un cuadro más bien ambiguo, y quien lleve a cabo la predicción deberá hacer una valoración en base a la información disponible sobre la cuestión de modelizar la inflación con una tendencia estocástica. Claramente, en la Figura 14.1a la inflación muestra cambios en el largo plazo, en consonancia con el modelo de tendencia estocástica. En la práctica, muchos analistas consideran la inflación en EE.UU. como una variable que presenta una tendencia estocástica, y aquí se sigue esta estrategia.

Resolución de los problemas originados por tendencias estocásticas

La manera más fiable de tratar la presencia de una tendencia en una serie consiste en transformar la serie de forma que desaparezca la tendencia. Si la serie tiene una tendencia estocástica, es decir, si la serie tiene una raíz unitaria, entonces la primera diferencia de la serie no tendrá tendencia. Por ejemplo, si Y_t sigue un paseo aleatorio, por lo que $Y_t = \beta_0 + Y_{t-1} + u_t$, entonces, $\Delta Y_t = \beta_0 + u_t$ es estacionaria. Por tanto, mediante la utilización de las primeras diferencias se elimina la tendencia de paseo aleatorio en una serie.

En la práctica, rara vez se puede asegurar que una serie tiene una tendencia estocástica. Recordemos que, como norma general, el hecho de no rechazar la hipótesis nula no significa necesariamente que la hipótesis nula sea verdadera; sino que simplemente significa que no se dispone de suficientes pruebas que permitan concluir que es falsa. Por tanto, cuando no se rechaza la hipótesis nula de una raíz unitaria mediante el contraste ADF, no significa que la serie en realidad *tenga* una raíz unitaria. Por ejemplo, en un modelo AR(1) el verdadero coeficiente β_1 podría estar muy cercano a uno, por ejemplo 0,98, en cuyo caso el contraste ADF tiene poca potencia, es decir, presenta una probabilidad baja de rechazar de forma correcta la hipótesis nula en las muestras con un tamaño muestral como el de nuestra serie de inflación. Incluso aunque no se rechace la hipótesis nula de presencia de raíz unitaria, no significa que la serie tenga una raíz unitaria, y aun podría ser razonable aproximar la verdadera raíz autorregresiva como si fuera igual a 1 y por lo tanto utilizar las diferencias de la serie en lugar de sus niveles⁵.

14.7 Ausencia de estacionariedad II: cambios estructurales

Un segundo tipo de no estacionariedad se presenta cuando la función de regresión poblacional cambia durante el transcurso de la muestra. En economía, esto puede ocurrir por varias razones, tales como la presencia de cambios en la política económica, cambios en la estructura de la economía, o un invento que cambie una industria en concreto. Si ocurren tales «cambios estructurales», o «rupturas», entonces un modelo de regresión que no tenga en cuenta esos cambios puede proporcionar una base engañosa para la inferencia y la predicción.

En esta sección se presentan dos estrategias para verificar la presencia de cambios estructurales en el tiempo de una función de regresión con series temporales. La primera estrategia busca los potenciales cambios estructurales desde el punto de vista de los contrastes de hipótesis y consiste en la contrastación de la existencia de cambios en los coeficientes de regresión mediante estadísticos F . La segunda estrategia busca los potenciales cambios estructurales desde el punto de vista de la predicción: se simula que la muestra termina antes de lo que realmente lo hace y se evalúan las predicciones que hubiesen sido realizadas de esta forma. Los cambios estructurales se detectan cuando la capacidad de predicción es sustancialmente peor de lo esperado.

¿Qué es un cambio estructural?

Los cambios estructurales pueden surgir debido tanto a un cambio discreto en los coeficientes de regresión poblacionales en un momento evidente, como a una evolución gradual de los coeficientes a lo largo de un horizonte temporal más prolongado.

Una fuente de cambios estructurales discretos en los datos macroeconómicos puede provenir de un cambio importante en la política macroeconómica. Por ejemplo, el colapso del sistema de tipos de cambio fijos de Bretton Woods en 1972 produjo un cambio estructural en el comportamiento de las series temporales del tipo de cambio \$/£ que se hace evidente en la Figura 14.2b. Antes de 1972, el tipo de cambio era prácticamente constante, con la excepción de una única devaluación en 1968 por la que el valor oficial de la libra, con respecto al dólar, se redujo. Por el contrario, desde 1972 el tipo de cambio ha fluctuado dentro de un rango muy amplio.

Los cambios estructurales pueden ocurrir asimismo más lentamente a medida que la regresión poblacional evoluciona en el tiempo. Por ejemplo, estos cambios pueden surgir debido a la lenta evolución de la política económica y los cambios consiguientes que provocan en la estructura de la economía. Los métodos para la detección de cambios estructurales descritos en esta sección pueden detectar ambos tipos de cambios estructurales, cambios evidentes y de evolución lenta.

Problemas ocasionados por los cambios estructurales. Si se produce un cambio estructural en la función de regresión poblacional a lo largo de la muestra, entonces la regresión estimada por MCO para la muestra completa estimará una relación que se cumplirá «en promedio», en el sentido de que la estimación

⁵ Para un análisis más amplio de las tendencias estocásticas en variables de series temporales económicas y de los problemas que suponen para el análisis de regresión, véase Stock y Watson (1988).

combinará ambos periodos diferentes. Dependiendo de la ubicación y del tamaño del cambio estructural, la función de regresión «promedio» podría ser muy diferente de la verdadera función de regresión al final de la muestra, y esto llevaría a malas predicciones.

Contrastes de cambio estructural

Una forma de detectar los cambios estructurales es la de contrastar la presencia de variaciones discretas, cambios estructurales, o puntos de ruptura, en los coeficientes de regresión. La forma de hacerlo dependerá de si el momento en el que se sospecha que se produce la ruptura o el cambio estructural (**punto de ruptura**) es conocido.

Contraste de cambio estructural con punto de ruptura conocido. En algunos casos concretos, se puede sospechar que existe un punto de ruptura en un momento conocido. Por ejemplo, si se están estudiando las relaciones comerciales internacionales con datos de la década de 1970, es posible plantear la hipótesis de que existe un cambio estructural en la función de regresión poblacional de interés en 1972, cuando se abandonó el sistema de tipos de cambio fijos de Bretton Woods en favor de la libre flotación de los tipos de cambio.

Si la fecha del hipotético cambio estructural en los coeficientes es conocida, entonces la hipótesis nula de ausencia de cambio estructural se puede contrastar mediante una regresión con variable binaria de interacción del tipo descrito en el Capítulo 8 (Concepto clave 8.4). Por simplicidad, se considera un modelo $ARD(1,1)$, por lo que existe un término independiente, un único retardo de Y_t , y un único retardo de X_t . Sea τ la expresión del periodo en el que se produce el cambio estructural hipotético y sea $D_t(\tau)$ una variable binaria que es igual a 0 antes del periodo del cambio estructural y 1 tras él, por lo que $D_t(\tau) = 0$ si $t \leq \tau$ y $D_t(\tau) = 1$ si $t > \tau$. Por tanto, la regresión que incluye el indicador binario del cambio estructural y todos los términos de interacción es

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_1 X_{t-1} + \gamma_0 D_t(\tau) + \gamma_1 [D_t(\tau) \times Y_{t-1}] + \gamma_2 [D_t(\tau) \times X_{t-1}] + u_t. \quad (14.35)$$

Si no existe cambio estructural, entonces la función de regresión poblacional es la misma en ambas partes de la muestra, por lo que los términos que incluyen la variable binaria de cambio estructural $D_t(\tau)$ no entran en la Ecuación (14.35). Es decir, bajo la hipótesis nula de ausencia de cambio estructural, $\gamma_0 = \gamma_1 = \gamma_2 = 0$. Bajo la hipótesis alternativa de que existe cambio estructural, entonces la función de regresión poblacional es diferente antes y después del punto de ruptura τ , en cuyo caso, al menos una de las γ es distinta de cero. Por tanto, la hipótesis de presencia de cambio estructural puede contrastarse mediante el estadístico F que contrasta la hipótesis de que $\gamma_0 = \gamma_1 = \gamma_2 = 0$ frente a la hipótesis de que al menos uno de los coeficientes γ es distinto de cero. Esto se suele denominar contraste de cambio estructural de Chow con punto de ruptura conocido, así denominado por su inventor, Gregory Chow (1960).

Si existen varios predictores o más retardos, este contraste puede ser ampliado mediante la adición de variables binarias de interacción para todos los regresores y contrastando la hipótesis de que todos los coeficientes de los términos que incluyen $D_t(\tau)$ son iguales a cero.

Este método puede modificarse para comprobar si existe cambio estructural en un subconjunto de coeficientes mediante la inclusión solamente de las variables binarias con interacción para el subconjunto de regresores que interese.

Contraste de cambio estructural con punto de ruptura desconocido. A menudo, el momento en el que puede producirse el posible cambio estructural es desconocido o conocido solamente dentro de un rango. Supóngase, por ejemplo, que se sospecha de que se produjo un cambio estructural entre dos periodos, τ_0 y τ_1 . El contraste de Chow puede ser modificado para abordar esta circunstancia mediante la contrastación de la existencia de cambio estructural en todos los posibles periodos τ que estén entre τ_0 y τ_1 , y a continuación, utilizando el mayor de los estadísticos F resultantes para contrastar un cambio estructural en un momento desconocido. Este contraste de Chow modificado se denomina indistintamente **estadístico de razón de verosimilitud de Quandt (QLR)** (Quandt, 1960) (la denominación que se utiliza en este libro), o *estadístico de supWald*.

Debido a que el estadístico QLR es el mayor de varios estadísticos F , su distribución no es la misma que la de un estadístico F individual. En su lugar, los valores críticos para el estadístico QLR deben ser obtenidos a partir de una distribución particular. Al igual que para el estadístico F , esta distribución depende de la cantidad de restricciones que se contrastan, q , es decir, el número de coeficientes (incluyendo el término independiente) que se permite que cambien, bajo la hipótesis alternativa. La distribución del estadístico QLR depende asimismo de τ_0/T y τ_1/T , es decir, de los últimos periodos, τ_0 y τ_1 , de las submuestras sobre las cuales se calculan los estadísticos F , expresados como una proporción del tamaño total de la muestra.

Para que la aproximación para grandes muestras de la distribución del estadístico QLR sea correcta, los últimos periodos de las submuestras, τ_0 y τ_1 , no pueden estar demasiado cerca del principio o del final de la muestra. Por esta razón, en la práctica, el estadístico QLR se calcula sobre un rango, o subconjunto, «reducido» de la muestra. Es habitual elegir un 15 % de «reducción», es decir, establecer $\tau_0 = 0,15T$ y $\tau_1 = 0,85T$ (redondeando al entero más cercano). Con el 15 % de reducción, se calcula el estadístico F para los puntos de ruptura que se encuentran en el 70 % central de la muestra.

Los valores críticos para el estadístico QLR, calculado con el 15 % de reducción, se ofrecen en la Tabla 14.6. Comparando estos valores críticos con los de la distribución $F_{q, \infty}$ (Tabla 4 del Apéndice) se hace evidente que los valores críticos para los estadísticos QLR son mayores. Esto refleja el hecho de que los

TABLA 14.6 Valores críticos del estadístico QLR con un 15 % de reducción

Número de restricciones (q)	10 %	5 %	1 %
1	7,12	8,68	12,16
2	5,00	5,86	7,78
3	4,09	4,71	6,02
4	3,59	4,09	5,12
5	3,26	3,66	4,53
6	3,02	3,37	4,12
7	2,84	3,15	3,82
8	2,69	2,98	3,57
9	2,58	2,84	3,38
10	2,48	2,71	3,23
11	2,40	2,62	3,09
12	2,33	2,54	2,97
13	2,27	2,46	2,87
14	2,21	2,40	2,78
15	2,16	2,34	2,71
16	2,12	2,29	2,64
17	2,08	2,25	2,58
18	2,05	2,20	2,53
19	2,01	2,17	2,48
20	1,99	2,13	2,43

Estos valores críticos son aplicables cuando $\tau_0 = 0,15T$ y $\tau_1 = 0,85T$ (redondeando al entero más cercano), por lo que el estadístico F se calcula para todos los puntos de ruptura potenciales del 70 % central de la muestra. El número de restricciones q es el número de restricciones contrastadas por cada estadístico F individual. Los valores críticos para otros porcentajes de reducción pueden encontrarse en Andrews (2003).

estadísticos QLR solo se fijan en el mayor de los estadísticos F . Examinando los estadísticos F para todos los posibles puntos de ruptura contemplados, el estadístico QLR tiene muchas oportunidades de rechazar la hipótesis nula, lo que conlleva que los valores críticos del QLR sean mayores que los del estadístico F individual.

Al igual que el contraste de Chow, el contraste QLR puede utilizarse enfocado a la posibilidad de que existan cambios estructurales solamente en algunos de los coeficientes de regresión. Esto se realiza calculando en primer lugar el contraste de Chow para distintos puntos de ruptura utilizando variables binarias con interacciones solamente para las variables de los coeficientes bajo sospecha, calculando a continuación el contraste de Chow máximo en el rango $\tau_0 \leq \tau \leq \tau_1$. Los valores críticos para esta versión del contraste QLR se toman asimismo de la Tabla 14.6, en la que el número de restricciones (q) es el número de restricciones contrastadas por el estadístico F correspondiente.

Si existe un cambio estructural discreto en un instante dentro del rango contrastado, entonces el estadístico QLR rechazará con alta probabilidad en muestras grandes. Por otra parte, el momento en que el estadístico F correspondiente es máximo, $\hat{\tau}$, es una estimación del punto de ruptura τ . Esta estimación es una buena estimación en el sentido de que, bajo ciertas condiciones técnicas, $\hat{\tau}/T \xrightarrow{p} \tau/T$; es decir, la proporción del tramo de la muestra en que se produce el cambio estructural se estima de manera consistente.

El estadístico QLR rechaza asimismo la hipótesis nula con una probabilidad alta en muestras grandes cuando existen varios cambios estructurales discretos o cuando el cambio estructural se presenta en forma de lenta evolución de la función de regresión. Esto significa que el estadístico QLR detecta formas de inestabilidad distintas a un único cambio estructural discreto. Como resultado, si el estadístico QLR rechaza la hipótesis nula, puede significar que existe un cambio estructural único y discreto, que existen varios cambios estructurales discretos, o que hay una evolución lenta de la función de regresión.

El estadístico QLR se recoge en el Concepto clave 14.9.

Advertencia: es probable que no se conozca el punto de ruptura incluso aunque se crea que sí. A veces un experto puede pensar que él, o ella, conoce el momento en el que se produce un posible cambio estructural por lo que puede utilizarse el contraste de Chow en lugar del contraste QLR. Pero si esta

**CONCEPTO
CLAVE**

14.9

El contraste QLR para la estabilidad de los coeficientes

Sea $F(\tau)$ la expresión del estadístico F para el contraste de la hipótesis de cambio estructural en los coeficientes de regresión en el momento τ ; por ejemplo, en la regresión de la Ecuación (14.35), este es el estadístico F para contrastar la hipótesis nula de que $\gamma_0 = \gamma_1 = \gamma_2 = 0$. El estadístico de contraste QLR (o de sup Wald) es el mayor de los estadísticos dentro del rango $\tau_0 \leq \tau \leq \tau_1$:

$$\text{QLR} = \max [F(\tau_0), F(\tau_0 + 1), \dots, F(\tau_1)]. \quad (14.36)$$


1. Al igual que el estadístico F , el estadístico QLR puede ser utilizado para contrastar la existencia de un cambio estructural en todos o solo en algunos de los coeficientes de regresión.
2. En muestras grandes, la distribución del estadístico QLR bajo la hipótesis nula depende del número de restricciones que se contrasten, q , y de los extremos τ_0 y τ_1 como proporción de T . Los valores críticos están recogidos en la Tabla 14.6 para un 15 % de reducción ($\tau_0 = 0,15T$ y $\tau_1 = 0,85T$, redondeando al entero más cercano).
3. El contraste QLR puede detectar la existencia de un único cambio estructural discreto, varios cambios estructurales discretos, y/o la evolución lenta de la función de regresión.
4. Si existe un cambio estructural evidente en la función de regresión, el periodo en el que se registra el estadístico de Chow mayor es un estimador del punto de ruptura.

información se basa en el conocimiento por parte del experto acerca de la serie que se analiza, entonces, de hecho, este momento fue estimado mediante los datos, aunque de manera informal. La estimación preliminar del punto de ruptura significa que los valores críticos habituales de F no pueden utilizarse para el contraste de Chow para un cambio estructural en ese momento. Por tanto, en estas circunstancias, sigue siendo apropiado utilizar el estadístico QLR.

Aplicación: ¿se ha mantenido estable la curva de Phillips? El contraste QLR proporciona un método para comprobar si la curva de Phillips se mantuvo estable desde 1962 hasta 2004. En concreto, nos centraremos en si hubo cambios en los coeficientes de los valores retardados de la tasa de desempleo y en el término independiente en la especificación ARD (4.4) de la Ecuación (14.17) que contiene cuatro retardos tanto de $\Delta \ln f_t$ como de $Desemp_t$.

Los estadísticos F de Chow para contrastar la hipótesis de que el término independiente y los coeficientes de $Desemp_{t-1}$, $Desemp_{t-2}$, ..., $Desemp_{t-4}$ en la Ecuación (14.17) son constantes frente a la alternativa de que cambian en un momento determinado están representados gráficamente en la Figura 14.5 para cambios estructurales en el 70 % central de la muestra. Por ejemplo, el estadístico F para contrastar un cambio estructural en 1980:I es de 2,85, el valor representado en ese periodo en la figura. Cada estadístico F contrasta cinco restricciones (no existe cambio estructural en el término independiente ni en los cuatro coeficientes de los retardos de la tasa de desempleo), por lo que $q = 5$. El mayor de estos estadísticos F es 5,16, que se produce en 1981:IV; este es el estadístico QLR. La comparación del valor 5,16 con el valor crítico para $q = 5$ de la Tabla 14.6 indica que la hipótesis de que estos coeficientes son estables se rechaza al nivel de significación del 1 % (el valor crítico es 4,53). Por tanto, existe evidencia de que al menos uno de estos cinco coeficientes cambió a lo largo del periodo muestral.

FIGURA 14.5 Estadísticos F para el contraste de cambio estructural en la ecuación (14.17) en diferentes periodos



En un punto de ruptura dado, el estadístico F representado aquí contrasta la hipótesis nula de presencia de cambio estructural en al menos uno de los coeficientes de, $Desemp_{t-1}$, $Desemp_{t-2}$, $Desemp_{t-3}$, $Desemp_{t-4}$ o el término independiente de la Ecuación (14.17). Por ejemplo, el estadístico F que contrasta la presencia de cambio estructural en 1980:I es 2,85. El estadístico QLR es el mayor de estos estadísticos F , que es 5,16. Esto supera el valor crítico al 1 % que es igual a 4,53.

Predicción pseudo fuera de la muestra

La prueba definitiva para un modelo de predicción es su rendimiento fuera la muestra, es decir, su capacidad de predecir en «tiempo real», después de que el modelo haya sido estimado. La **predicción pseudo fuera de la muestra** es un método para simular el rendimiento en tiempo real de un modelo de predicción. La idea de la predicción pseudo fuera de la muestra es sencilla: elegir un periodo cercano al final de la muestra, estimar el modelo de predicción a partir de los datos hasta ese periodo, y más tarde utilizar ese modelo estimado para realizar una predicción. La realización de este ejercicio para varios periodos, cercanos al final de la muestra, da lugar a una serie de pseudo predicciones y de pseudo errores de predicción. Los pseudo errores de predicción pueden ser examinados para comprobar si son representativos de lo que cabría esperar si la relación de predicción fuera estacionaria.

La razón por la que se denomina predicción «pseudo» fuera de la muestra es que no se trata de una verdadera predicción fuera de la muestra. La predicción fuera de la muestra se realiza en tiempo real; es decir, el pronóstico se realiza sin el beneficio de conocer los valores futuros de la serie. En la predicción pseudo fuera de muestra, se simula la predicción en tiempo real mediante el modelo, pero se dispone de los datos «futuros» frente a los que se evalúan los simulados, o pseudo predicciones. La predicción fuera de la muestra imita el proceso de predicción que se produciría en tiempo real, pero sin tener que esperar a que lleguen nuevos datos.

La predicción pseudo fuera de la muestra proporciona a quien pronostica una señal acerca de lo bien que el modelo de predicción ha realizado las predicciones al final de la muestra. Esto puede proporcionar información valiosa, ya sea reforzando la confianza porque el modelo ya se ha comportado bien al pronosticar, o bien sugiriendo que el modelo ya se ha salido de la senda correcta en el pasado reciente. La metodología de la predicción pseudo fuera de la muestra se resume en el Concepto clave 14.10.

Otras utilidades de las predicciones pseudo fuera de la muestra. Una segunda utilidad de la predicción pseudo fuera de la muestra consiste en estimar la RECMF. Debido a que la predicción pseudo fuera de la muestra se calcula utilizando solamente los datos previos al momento de la predicción, los errores de predicción pseudo fuera de la muestra reflejan tanto la incertidumbre asociada a los valores futuros del término de error como la incertidumbre que aparece debido a que los coeficientes de regresión son estimados; es decir, los errores de predicción pseudo fuera de la muestra incluyen las dos fuentes de error de la Ecuación (14.21). Por tanto, la desviación típica muestral de los errores de predicción pseudo fuera de la muestra es un estimador de la RECMF. Tal y como ya se ha discutido en la Sección 14.4, este estimador de la RECMF se puede utilizar para cuantificar la incertidumbre de la predicción y para construir intervalos de predicción.

Una tercera utilidad de la predicción pseudo fuera de la muestra es la de comparar dos o más modelos candidatos a ser utilizados para predicción. Dos modelos que parezcan ajustarse bien a los datos pueden comportarse, sin embargo, de manera muy diferente en un ejercicio de predicción pseudo fuera de la mues-

CONCEPTO CLAVE

14.10

Predicciones pseudo fuera de la muestra

Las predicciones pseudo fuera de la muestra se calculan siguiendo los siguientes pasos:

1. Elegir un número de observaciones, P , para las que se van a generar las predicciones pseudo fuera de la muestra; por ejemplo, P podría ser el 10 % o el 15 % del tamaño de la muestra. Sea $s = T - P$.
2. Estimar la regresión de predicción con el conjunto de datos reducido para $t = 1, \dots, s$.
3. Calcular la predicción para el primer periodo más allá de esta muestra reducida, $s + 1$; y denominarlo $\tilde{Y}_{s+1|s}$.
4. Calcular el error de predicción, $\tilde{u}_{s+1} = Y_{s+1} - \tilde{Y}_{s+1|s}$.
5. Repetir los pasos 2 a 4 para los periodos restantes, $s = T - P + 1$ hasta $T - 1$ (reestimando la regresión para cada periodo). Las predicciones pseudo fuera de la muestra son $\{\tilde{Y}_{s+1|s}, s = T - P, \dots, T - 1\}$, y los errores de predicción pseudo fuera de la muestra son $\{\tilde{u}_{s+1}, s = T - P, \dots, T - 1\}$.

¿Se puede batir al mercado? Parte II

Quizás haya escuchado alguna vez el consejo de que debe comprarse una acción cuando los dividendos que genera son elevados en relación a su precio. Comprar una acción supone, en efecto, la compra del flujo de los dividendos futuros pagados por esa compañía a cuenta de sus beneficios. Si el flujo de dividendos es inusualmente grande en relación con el precio de las acciones de la compañía, entonces podría considerarse que la empresa está infravalorada. Si ocurre que los dividendos actuales constituyen un indicador de los futuros dividendos, entonces la rentabilidad por dividendo —el cociente entre los dividendos actuales y el precio de la acción— podría predecir una rentabilidad extraordinaria futura de las acciones. Si la rentabilidad por dividendo es elevada, la acción está infravalorada y se podría prever que la rentabilidad suba.

Este razonamiento sugiere un examen mediante modelos autorregresivos de retardos distribuidos de la rentabilidad extraordinaria, en los que la variable predictora sea la rentabilidad por dividendo. Sin embargo, con este método surge una dificultad: la rentabilidad por dividendo es muy persistente e incluso podría ocurrir que contuviese una tendencia estocástica. Utilizando los datos mensuales desde 1960:1 hasta 2002:12 del logaritmo del cociente dividendos-precio para el índice CRSP (los datos están descritos en el Apéndice 14.1), un contraste de raíz unitaria de Dickey-Fuller que incluye un término independiente no rechaza la hipótesis nula de existencia de una raíz unitaria al nivel de significación del 10 %. Como siempre, el hecho de que no se rechace la hipótesis nula no significa que la hipótesis nula sea cierta, pero subraya el hecho de que la rentabilidad por dividendo es un regresor muy persistente. Siguiendo la lógica de la Sección 14.6, este resultado sugiere que debería utilizarse la primera diferencia del logaritmo de la rentabilidad por dividendo como regresor, en lugar del nivel del logaritmo de la rentabilidad por dividendo.

En la Tabla 14.7 se presentan los modelos ARD para la rentabilidad extraordinaria sobre el índice CRSP. En las columnas (1) y (2), la rentabilidad por dividendo aparece en primeras diferencias, y los estadísticos t individuales y los estadísticos F conjuntos no rechazan la hipótesis nula de impredecibilidad. Sin embargo, aunque estas especificaciones son acordes con las recomendaciones para la modelización de la Sección 14.6, no se corresponden con el razonamiento económico del párrafo introductorio, que relaciona la rentabilidad con el nivel de la rentabilidad por dividendo. La columna (3) de la Tabla 14.7 por tanto, presenta un modelo ARD(1,1) para la rentabilidad extraordinaria utilizando el logaritmo de la rentabilidad por dividendo, que se estima hasta 1992:12. El estadístico t es igual a 2,25, lo que supera el valor crítico habitual del 5 % que es igual a 1,96. Sin embargo, debido a que el regresor es muy persistente, la distribución de este estadístico t resulta sospechosa y el valor crítico 1,96 puede ser

inadecuado. (el estadístico F de esta regresión no se presenta debido a que no necesariamente tiene una distribución chi-cuadrado, incluso en muestras grandes, debido a la persistencia del regresor).

Una forma de evaluar la aparente predictibilidad hallada en la columna (3) de la Tabla 14.7 consiste en llevar a cabo un análisis de predicción pseudo fuera de la muestra. Haciéndolo para el periodo fuera de la muestra 1993:1-2002:12 se obtiene una raíz del error cuadrático medio de predicción muestral del 4,08 %. Por el contrario, la RECMF muestral de que todas las rentabilidades extraordinarias predichas son iguales a cero es del 4,00 %, y la RECMF muestral de una «predicción constante» (en la que el modelo de predicción estimado recursivamente incluye solamente un término independiente) es de 3,98 %. La predicción pseudo fuera de la muestra basada en el modelo ARD(1,1) con el logaritmo de la rentabilidad por dividendo ¡es peor que las predicciones en las que no hay predictores!

Esta ausencia de predictibilidad es consistente con la versión fuerte de la hipótesis de los mercados eficientes, que sostiene que toda la información disponible al público está incorporada en los precios de las acciones por lo que las rentabilidades no deberían ser predecibles mediante la información disponible al público (la versión débil se refiere solamente a las previsiones basadas en las rentabilidades pasadas). El mensaje central de que las rentabilidades extraordinarias no son fácilmente predecibles tiene sentido: si lo fueran, los precios de las acciones subirían hasta el punto en que no existiera rentabilidad extraordinaria. La interpretación de resultados como los de la Tabla 14.7 es objeto de un debate acalorado entre los economistas financieros.

Algunos consideran que la ausencia de predictibilidad en las regresiones predictivas constituye una reivindicación de la hipótesis de los mercados eficientes (véase, por ejemplo, Goyal y Welch, 2003). Otros dicen que cuando se analizan las regresiones durante periodos de tiempo más largos y a más largo plazo, y se utilizan herramientas que están específicamente diseñadas para tratar regresores persistentes, aparece evidencia de la existencia de predictibilidad (véase Campbell y Yogo, 2006). Esta predictibilidad pudiera derivarse de un comportamiento económico racional, bajo el cual las actitudes de los inversores hacia el riesgo varían a lo largo del ciclo económico (Campbell, 2003), o pudiera reflejar la «exuberancia irracional» (Shiller, 2005).

Los resultados de la Tabla 14.7 se refieren a rentabilidades mensuales, pero algunos economistas financieros se han centrado en horizontes incluso más cortos. La teoría de la «microestructura del mercado» —los movimientos de las acciones en el mercado minuto a minuto— sugiere que podrían existir periodos fugaces de predictibilidad y que puede ganarse dinero si se es inteligente y ágil. Pero para ello son necesarios unos nervios templados, además de un montón de potencia computacional, así como un equipo de economistas con talento.

(continúa)

TABLA 14.7 Modelos autorregresivos de retardos distribuidos para la rentabilidad mensual extraordinaria de las acciones

Variable dependiente: rentabilidad extraordinaria en el índice CPRS por capitalización ponderado			
	(1)	(2)	(3)
Especificación	ADL (1,1)	ADL (2,2)	ADL (1,1)
Periodo de estimación	1960:1– 2002:12	1960:1– 2002:12	1960:1– 1992:12
Variables explicativas			
Rentabilidad extraordinaria _{t-1}	0,059 (0,158)	0,042 (0,162)	0,078 (0,057)
Rentabilidad extraordinaria _{t-2}		-0,213 (0,193)	
$\Delta \ln$ (rentabilidad por dividendo _t)	0,009 (0,157)	-0,012 (0,163)	
$\Delta \ln$ (rentabilidad por dividendo _{t-1})		-0,161 (0,185)	
$\ln$ (rentabilidad por dividendo _{t-2})			0,026 ^a (0,012)
Término independiente	0,0031 (0,0020)	0,0037 (0,0021)	0,090 ^a (0,039)
Estadístico F sobre todos los coeficientes (p -valor)	0,501 (0,0606)	0,843 (0,497)	
$\bar{R}^2$	-0,0014	-0,0008	0,0134

Notas: Los datos se describen en el Apéndice 14.1. En las casillas de las filas de las variables explicativas se presentan los coeficientes de los regresores, con los errores estándar entre paréntesis. Las dos últimas filas presentan el estadístico F para el contraste de la hipótesis de que todos los coeficientes de la regresión son iguales a cero, con su p -valor entre paréntesis, y el $\bar{R}^2$ ajustado.

^a $|t| > 1,96$.

tra. Cuando los modelos son diferentes, por ejemplo, cuando incluyen diferentes predictores, la predicción pseudo fuera de la muestra proporciona un modo apropiado de comparar los dos modelos que se centra en su potencial para proporcionar pronósticos fiables.


Aplicación: ¿cambió la curva de Phillips durante la década de 1990? Utilizando el estadístico QLR, se rechaza la hipótesis nula de que la curva de Phillips se mantuvo estable frente a la alternativa de presencia de cambio estructural al nivel de significación del 1 % (véase la Figura 14.5). El estadístico F máximo se produce en 1981:IV, lo que indica que el cambio estructural se produjo al principio de la década de 1980. Esto indica que alguien que quisiera predecir utilizando la variable de desempleo retardada debería utilizar una muestra para la estimación que comience tras el cambio estructural de 1981:IV. Aun así, quedaría una pregunta por resolver: ¿constituye la curva de Phillips un modelo de predicción estable tras el cambio estructural de 1981:IV?

Si los coeficientes de la curva de Phillips cambiaron en algún momento a lo largo del periodo 1982:I–2004:I, entonces las predicciones pseudo fuera de la muestra calculadas con los datos a partir de 1982:I no serían buenas. Las predicciones de inflación pseudo fuera de la muestra para el periodo 1999:I–2004:IV, calculadas a partir de la curva de Phillips con cuatro retardos y estimada con los datos a partir de 1982:I, están representadas en la Figura 14.6, junto con los verdaderos valores de la inflación. Por ejemplo, la previsión de inflación para 1999:I fue calculada mediante la regresión de la variable $\Delta \ln f_t$ sobre $\Delta \ln f_{t-1}, \dots, \Delta \ln f_{t-4}, \text{Desemp}_{t-1}, \dots, \text{Desemp}_{t-4}$, con un término independiente utilizando los datos hasta

1998:IV, y a continuación, calculando la predicción $\widehat{\Delta Inf}_{1999:I|1998:IV}$ utilizando estos coeficientes estimados y los datos hasta 1998:IV. La predicción de inflación para 1999:I es por lo tanto $\widehat{Inf}_{1999:I|1998:IV} = Inf_{1998:IV} + \widehat{\Delta Inf}_{1999:I|1998:IV}$. Este mismo procedimiento se repitió en su totalidad utilizando los datos hasta 1999:I para calcular la predicción $\widehat{\Delta Inf}_{1999:II|1999:I}$. Haciendo lo mismo para los 24 trimestres desde 1999:I hasta 2004:IV se generan 24 predicciones pseudo fuera de la muestra, que están representadas en la Figura 14.6. Los errores de predicción pseudo fuera de la muestra son las diferencias entre la verdadera inflación y su predicción pseudo fuera de la muestra, es decir, las diferencias entre las dos líneas de la Figura 14.6. Por ejemplo, en el periodo 2000:IV, la tasa de inflación se redujo en 0,8 puntos porcentuales, pero la predicción pseudo fuera de la muestra para $\Delta Inf_{2000:IV}$ fue de 0,3 puntos porcentuales, por lo que el error de predicción pseudo fuera de la muestra fue $\Delta Inf_{2000:IV} - \widehat{\Delta Inf}_{2000:IV|2000:III} = -0,8 - 0,3 = -1,1$ puntos porcentuales. En otras palabras, alguien que quisiera predecir mediante el modelo $ARD(4,4)$ para la curva de Phillips, estimado hasta el periodo 2000:III, habría pronosticado que la inflación se incrementaría en 0,3 puntos porcentuales en el periodo 2000:IV, cuando en realidad se redujo en 0,8 puntos porcentuales.

¿Cómo se comparan la media y la desviación típica de los errores de predicción pseudo fuera de la muestra con el ajuste del modelo dentro de la muestra? El error estándar de la regresión de la curva de Phillips con cuatro retardos, ajustada con los datos que van desde el periodo 1982:I hasta el periodo 1998:IV, es de 1,30, por lo que en base al ajuste dentro de la muestra podría esperarse que el error de predicción fuera de la muestra tuviera una media igual a cero y una raíz cuadrada del error cuadrático medio de predicción D , 1,30. De hecho, a lo largo del periodo de predicción pseudo fuera de la muestra 1999:I-2004:IV, el promedio del error de predicción es de 0,11 y el estadístico t para contrastar la hipótesis de que la media del error de predicción es igual a cero es 0,41; por lo que no se rechaza la hipótesis de que las predicciones tienen una

FIGURA 14.6 Inflación en EE.UU. y predicciones pseudo fuera de muestra



Las predicciones pseudo fuera de muestra, realizadas mediante una curva de Phillips con cuatro retardos de la forma descrita por la Ecuación (14.17), en general siguen la senda de la inflación realmente registrada y son consistentes con un modelo de predicción de la curva de Phillips estable post-1982.

media igual a cero. Además, la RECMP a lo largo del periodo de predicción pseudo fuera de la muestra es de 1,32, muy cerca del valor de 1,30 para el error estándar de la regresión a lo largo del periodo 1982:I-1998:IV. Por otra parte, el gráfico de las predicciones y de los errores de predicción de la Figura 14.6 no muestra valores atípicos importantes o discrepancias inusuales.

De acuerdo con el ejercicio de predicción pseudo fuera de la muestra, el comportamiento del modelo de predicción de la curva de Phillips a lo largo del periodo pseudo fuera de la muestra 1999:I-2004:IV fue comparable a su comportamiento a lo largo del periodo 1982:I-1998:IV dentro de la muestra. Aunque el contraste QLR apunta a la inestabilidad de la curva de Phillips en la primera parte de la década de 1980, este análisis pseudo fuera de la muestra sugiere que, tras el cambio estructural en los primeros años de la década de 1980, el modelo de predicción de la curva de Phillips se ha mantenido estable.

Resolución de los problemas originados por cambios estructurales

La mejor manera de adaptarse a un cambio estructural en la función de regresión poblacional depende del origen del cambio estructural. Si el cambio estructural se produce claramente en una fecha específica, este cambio estructural se podrá detectar con alta probabilidad mediante el estadístico QLR, y se podrá estimar el punto de ruptura. Por tanto, la función de regresión podrá estimarse utilizando una variable binaria que indique las dos submuestras asociadas a ese cambio estructural, con interacciones con el resto de los regresores si resulta necesario. Si se produce un cambio estructural en todos los coeficientes, entonces esta regresión tomará la forma de la Ecuación (14.35), donde τ se reemplaza por el punto de ruptura estimado, $\hat{\tau}$, mientras que si el cambio estructural se produce solamente en algunos de los coeficientes, solo aparecerán en la regresión los términos de interacción relevantes. Si existe de hecho un cambio estructural evidente, entonces la inferencia sobre los coeficientes de regresión puede realizarse como de costumbre, por ejemplo, utilizando los valores críticos de la normal para los contrastes de hipótesis basados en los estadísticos t . Además, pueden realizarse las predicciones mediante la función de regresión estimada que es aplicable al final de la muestra.

Si el cambio estructural no es evidente, sino que más bien surge debido a un cambio lento y constante en los parámetros, el remedio resulta más difícil y queda fuera del alcance de este libro⁶.

14.8 Conclusión

En datos de series temporales, en general, una variable está correlacionada entre una observación, o periodo temporal, y la siguiente. Una consecuencia de esta correlación es que la regresión lineal se puede utilizar para predecir los valores futuros de una serie temporal en base a sus valores actuales y pasados. El punto de partida para la regresión de series temporales es una autorregresión, en la que los regresores son los valores retardados de la variable dependiente. Si se dispone de predictores adicionales, entonces se pueden añadir sus retardos a la regresión.

En este capítulo se han analizado algunas cuestiones técnicas que surgen al estimar y utilizar regresiones con datos de series temporales. Una de ellas es la determinación del número de retardos a incluir en las regresiones. Tal y como se trató en la Sección 14.5, si el número de retardos se elige de forma que se minimice el criterio BIC, la longitud estimada de los retardos es consistente con la verdadera longitud de los retardos.

Otra de estas cuestiones se refiere al hecho de si las series analizadas son estacionarias. Si las series son estacionarias, entonces pueden utilizarse los métodos habituales para realizar la inferencia estadística (como la comparación de los estadísticos t con los valores críticos normales), y debido a que la función de regresión poblacional es estable en el tiempo, las regresiones estimadas utilizando datos históricos pueden ser utilizadas de forma fiable para la predicción. Sin embargo, si las series son no estacionarias, entonces las cosas se vuelven más complicadas, y la complicación específica dependerá de la naturaleza de la no estacio-

⁶ Para un estudio más avanzado de la estimación y la contrastación en presencia de cambios estructurales discretos, véase Hansen (2001). Para un análisis más avanzado sobre la estimación y la predicción cuando existen coeficientes que evolucionan lentamente, véase Hamilton (1994, Capítulo 13).

nariedad. Por ejemplo, si las series son no estacionarias debido a que tienen una tendencia estocástica, entonces el estimador MCO y el estadístico t pueden presentar unas distribuciones no estándar (no normales), incluso en muestras grandes, y el comportamiento de las predicciones puede mejorarse mediante la especificación de la regresión en primeras diferencias. En la Sección 14.6 se introdujo un contraste para la detección de este tipo de no estacionariedad, el contraste de raíz unitaria de Dickey-Fuller. Por otra parte, si la función de regresión poblacional presenta un cambio estructural, de ignorar este cambio estructural se obtiene como resultado una versión promedio a partir de la estimación de la función de regresión poblacional, lo que a su vez puede conducir a predicciones sesgadas y/o imprecisas. Los procedimientos para la detección de un cambio estructural en la función de regresión poblacional se introdujeron en la Sección 14.7.

En este capítulo, se han aplicado los métodos de regresión de series temporales a la predicción económica, y no se ha dado una interpretación causal a los coeficientes de estos modelos. No es necesaria una relación causal para la predicción, y al ignorar las interpretaciones causales se permite mayor libertad para la búsqueda de buenos pronósticos. Sin embargo, en algunas aplicaciones, el objetivo no es el de desarrollar un modelo de predicción, sino más bien el de estimar las relaciones causales entre las variables de series temporales, es decir, el de estimar el efecto causal *dinámico* sobre Y a lo largo del tiempo de un cambio en X . Bajo las condiciones adecuadas, los métodos presentados en este capítulo, u otros métodos estrechamente relacionados, se pueden utilizar para estimar los efectos causales dinámicos, y este es el tema del siguiente capítulo.

Resumen

1. No es necesario que los modelos de regresión utilizados para la predicción tengan una interpretación causal.
2. Una variable de serie de temporal generalmente está correlacionada con uno o más de sus valores retardados, es decir, está serialmente correlacionada.
3. Un modelo autorregresivo de orden p es un modelo de regresión lineal múltiple en el que los regresores son los p primeros retardos de la variable dependiente. Los coeficientes de un modelo $AR(p)$ pueden estimarse mediante MCO, y la función de regresión estimada puede utilizarse para predicción. El orden del retardo p se puede estimar utilizando un criterio de información como el BIC.
4. La adición de otras variables y de sus retardos a una autorregresión puede mejorar el resultado de las predicciones. Bajo los supuestos de mínimos cuadrados para la regresión de series temporales (Concepto clave 14.6), los estimadores MCO tienen distribuciones normales en muestras grandes y la inferencia estadística se lleva a cabo del mismo modo que para datos de sección cruzada.
5. Los intervalos de predicción constituyen una forma de cuantificar la incertidumbre de la predicción. Si los errores se distribuyen normalmente, se puede construir un intervalo de predicción aproximadamente del 68 % como la predicción, más o menos una estimación de la raíz del error cuadrático medio de predicción.
6. Una serie que contiene una tendencia estocástica es no estacionaria, lo que viola el segundo supuesto de mínimos cuadrados del Concepto clave 14.6. El estimador MCO y el estadístico t para el coeficiente de un regresor con una tendencia estocástica pueden tener una distribución no estándar, lo que potencialmente puede conducir a estimadores sesgados, predicciones ineficientes e inferencias erróneas. El estadístico ADF se puede utilizar para contrastar la presencia de una tendencia estocástica. Una tendencia estocástica de paseo aleatorio puede eliminarse por medio de las primeras diferencias de la serie.
7. Si la función de regresión poblacional cambia a lo largo del tiempo, las estimaciones MCO que ignoran esta inestabilidad no resultan fiables para la inferencia estadística o la predicción. El estadístico QLR puede utilizarse para contrastar la presencia de un cambio estructural, y, si se halla un cambio estructural discreto, la función de regresión puede reestimarse de forma que incorpore el cambio estructural.
8. Las predicciones pseudo fuera de la muestra pueden ser utilizadas para evaluar la estabilidad del modelo al final de la muestra, para estimar la raíz del error cuadrático medio de predicción, y para comparar diferentes modelos de predicción.