

Resumen: Capítulo 2

Modelos de Series de Tiempo Estacionarias
Enders, W. *Applied Econometric Time Series* (4ta ed.)

Mayo 2026

Índice

1. Modelos de Ecuaciones en Diferencias Estocásticas <i>(Stochastic Difference Equation Models)</i>	2
1.1. Proceso de Ruido Blanco (<i>White-Noise Process</i>)	2
1.2. Proceso de Promedio Móvil (<i>Moving Average Process</i>)	2
2. Modelos ARMA (<i>ARMA Models</i>)	2
3. Estacionariedad (<i>Stationarity</i>)	3
3.1. Restricciones de Estacionariedad para AR(1) <i>(Stationarity Restrictions for an AR(1) Process)</i>	3
4. Restricciones de Estacionariedad para ARMA(p, q) <i>(Stationarity Restrictions for an ARMA(p, q) Model)</i>	4
4.1. Restricciones para Coeficientes de Promedio Móvil	4
4.2. Restricciones para Coeficientes Autorregresivos <i>(Stationarity Restrictions for the Autoregressive Coefficients)</i>	4
5. La Función de Autocorrelación (<i>The Autocorrelation Function</i>)	5
5.1. ACF de un Proceso AR(1)	5
5.2. ACF de un Proceso AR(2)	5
5.3. ACF de un Proceso MA(1)	5
5.4. ACF de un Proceso ARMA(1,1)	6
6. La Función de Autocorrelación Parcial <i>(The Partial Autocorrelation Function)</i>	6
7. Autocorrelaciones Muestrales de Series Estacionarias <i>(Sample Autocorrelations of Stationary Series)</i>	7
7.1. Estadísticos Q de Box-Pierce y Ljung-Box	7
7.2. Criterios de Selección de Modelos (<i>Model Selection Criteria</i>)	7

8. Selección de Modelos Box-Jenkins (<i>Box-Jenkins Model Selection</i>)	8
8.1. Parsimonia (<i>Parsimony</i>)	8
8.2. Estacionariedad e Invertibilidad (<i>Stationarity and Invertibility</i>)	8
8.3. Bondad de Ajuste (<i>Goodness of Fit</i>)	9
8.4. Evaluación Postestimación (<i>Postestimation Evaluation</i>)	9
9. Propiedades de los Pronósticos (<i>Properties of Forecasts</i>)	9
9.1. Modelos de Orden Superior (<i>Higher-Order Models</i>)	10
9.2. Evaluación de Pronósticos (<i>Forecast Evaluation</i>)	10
9.2.1. Prueba de Granger-Newbold (<i>The Granger-Newbold Test</i>)	10
9.2.2. Prueba de Diebold-Mariano (<i>The Diebold-Mariano Test</i>)	10
10. Un Modelo del Diferencial de Tasas de Interés	
(<i>A Model of the Interest Rate Spread</i>)	10
11. Estacionalidad (<i>Seasonality</i>)	11
11.1. Modelos de Datos Estacionales (<i>Models of Seasonal Data</i>)	11
11.2. Diferenciación Estacional (<i>Seasonal Differencing</i>)	11
12. Inestabilidad de Parámetros y Cambio Estructural	
(<i>Parameter Instability and Structural Change</i>)	11
12.1. Prueba de Cambio Estructural (<i>Testing for Structural Change</i>)	12
12.2. Quiebres Endógenos (<i>Endogenous Breaks</i>)	12
12.3. Inestabilidad de Parámetros (<i>Parameter Instability</i>)	12
13. Combinación de Pronósticos (<i>Combining Forecasts</i>)	12
13.1. Pesos Óptimos (<i>Optimal Weights</i>)	13
14. Resumen y Conclusiones (<i>Summary and Conclusions</i>)	13

1. Modelos de Ecuaciones en Diferencias Estocásticas (*Stochastic Difference Equation Models*)

Las series de tiempo económicas se trabajan en tiempo **discreto** / **discrete** (no continuo). El índice t representa períodos ordenados; no necesariamente unidades físicas de tiempo.

Una variable discreta y es **aleatoria** / **random** (estocástica) si para todo número real r existe una probabilidad $p(y \leq r)$. Si $p(y = r) = 1$, la variable es determinista.

Los elementos de la serie observada $\{y_0, y_1, \dots, y_T\}$ son **realizaciones** / **realizations** (resultados observados) de un proceso estocástico. El valor esperado condicional de y_{t+i} dado el conjunto de información en t se denota $E_t y_{t+i}$.

Las **ecuaciones en diferencias estocásticas** / **stochastic difference equations** son una forma conveniente de modelar procesos económicos dinámicos.

1.1. Proceso de Ruido Blanco (*White-Noise Process*)

La secuencia $\{\varepsilon_t\}$ es un proceso de **ruido blanco** / **white-noise** si para todo período t :

$$\begin{aligned} E(\varepsilon_t) &= 0 \\ E(\varepsilon_t^2) &= \sigma^2 \\ E(\varepsilon_t \varepsilon_{t-s}) &= 0 \quad \text{para todo } s \neq 0 \end{aligned} \tag{1}$$

Es decir: media cero, varianza constante σ^2 y no correlación con sus propios rezagos.

1.2. Proceso de Promedio Móvil (*Moving Average Process*)

Usando ruido blanco se construye la serie de **promedio móvil** / **moving average** de orden q , $\text{MA}(q)$:

$$x_t = \sum_{i=0}^q \beta_i \varepsilon_{t-i} \tag{2}$$

2. Modelos ARMA (*ARMA Models*)

Combinando una ecuación autorregresiva de orden p con un $\text{MA}(q)$ se obtiene el modelo **ARMA**(p, q):

$$y_t = a_0 + \sum_{i=1}^p a_i y_{t-i} + \sum_{i=0}^q \beta_i \varepsilon_{t-i} \tag{3}$$

Si $q = 0$, el proceso es autorregresivo puro **AR**(p); si $p = 0$, es **MA**(q) puro. Usando operadores de rezago L (donde $L^j y_t = y_{t-j}$):

$$\left(1 - \sum_{i=1}^p a_i L^i\right) y_t = a_0 + \sum_{i=0}^q \beta_i \varepsilon_{t-i} \tag{4}$$

La solución particular expresa y_t en términos de $\{\varepsilon_t\}$ y se llama **representación de promedio móvil / moving average representation**:

$$y_t = \left(a_0 + \sum_{i=0}^q \beta_i \varepsilon_{t-i} \right) / \left(1 - \sum_{i=1}^p a_i L^i \right) \quad (5)$$

Si una o más raíces características igualan o superan la unidad, $\{y_t\}$ es un proceso **integrado / integrated** y el modelo completo se denomina **ARIMA** (AutoRegresivo Integrado de Promedio Móvil). La condición de estabilidad —necesaria para la estacionariedad— exige que las raíces del polinomio $(1 - \sum a_i L^i)$ se ubiquen *fuera* del círculo unitario.

3. Estacionariedad (*Stationarity*)

Cuando el econometrista solo dispone de una realización, si $\{y_t\}$ es **estacionaria / stationary**, la media, varianza y autocovarianzas pueden aproximarse mediante **promedios temporales / time averages**.

Un proceso estocástico es **estacionario en covarianza / covariance stationary** (también llamado **débilmente estacionario / weakly stationary** o estacionario en sentido amplio) si para todo t y $t - s$:

$$E(y_t) = E(y_{t-s}) = \mu \quad (6)$$

$$E[(y_t - \mu)^2] = \sigma_y^2 \quad (7)$$

$$E[(y_t - \mu)(y_{t-s} - \mu)] = \gamma_s \quad (8)$$

donde μ , σ_y^2 y γ_s son constantes.

La **autocorrelación / autocorrelation** entre y_t e y_{t-s} :

$$\rho_s \equiv \gamma_s / \gamma_0 \quad (9)$$

Un proceso **fuertemente estacionario / strongly stationary** no requiere media ni varianza finitas; el texto trabaja sólo con series estacionarias en covarianza.

3.1. Restricciones de Estacionariedad para AR(1) (*Stationarity Restrictions for an AR(1) Process*)

Para $y_t = a_0 + a_1 y_{t-1} + \varepsilon_t$, la solución general es:

$$y_t = a_0 \sum_{i=0}^{t-1} a_1^i + a_1^t y_0 + \sum_{i=0}^{t-1} a_1^i \varepsilon_{t-i} \quad (10)$$

Cuando $t \rightarrow \infty$ y $|a_1| < 1$, la secuencia converge a:

$$\lim_{t \rightarrow \infty} y_t = \frac{a_0}{1 - a_1} + \sum_{i=0}^{\infty} a_1^i \varepsilon_{t-i} \quad (11)$$

con media $\mu = a_0/(1 - a_1)$, varianza $\sigma^2/(1 - a_1^2)$ y autocovarianza:

$$\gamma_s = \frac{\sigma^2 (a_1)^s}{1 - (a_1)^2} \quad (12)$$

Las condiciones de estabilidad generalizables a todo ARMA(p, q) son:

1. La solución homogénea debe ser cero (el proceso comenzó infinitamente en el pasado, o bien la constante arbitraria $A = 0$).
2. La raíz característica a_1 debe ser menor que la unidad en valor absoluto.

4. Restricciones de Estacionariedad para ARMA(p, q) (*Stationarity Restrictions for an ARMA(p, q) Model*)

Para el ARMA(2,1): $y_t = a_1 y_{t-1} + a_2 y_{t-2} + \varepsilon_t + \beta_1 \varepsilon_{t-1}$, la solución particular se escribe $y_t = \sum_{i=0}^{\infty} c_i \varepsilon_{t-i}$, donde:

$$\begin{aligned} c_0 &= 1 \\ c_1 &= a_1 + \beta_1 \\ c_i &= a_1 c_{i-1} + a_2 c_{i-2}, \quad i \geq 2 \end{aligned} \quad (13)$$

4.1. Restricciones para Coeficientes de Promedio Móvil

Para cualquier MA(∞): $x_t = \sum_{i=0}^{\infty} \beta_i \varepsilon_{t-i}$, las condiciones necesarias y suficientes de estacionariedad en covarianza son que $\sum (\beta_i)^2$ y $(\beta_s + \beta_1 \beta_{s+1} + \beta_2 \beta_{s+2} + \dots)$ sean finitas.

4.2. Restricciones para Coeficientes Autorregresivos (*Stationarity Restrictions for the Autoregressive Coefficients*)

Para el AR(p) puro:

$$y_t = a_0 + \sum_{i=1}^p a_i y_{t-i} + \varepsilon_t \quad (14)$$

Si las raíces características del polinomio homogéneo están dentro del círculo unitario, la solución particular converge y la media es:

$$E y_t = \frac{a_0}{1 - \sum_{i=1}^p a_i} \quad (15)$$

Los coeficientes c_i de la representación MA(∞) satisfacen:

$$c_i - a_1 c_{i-1} - a_2 c_{i-2} - \dots - a_p c_{i-p} = 0 \quad (16)$$

Para el ARMA(p, q) general, solo la parte autorregresiva determina la estacionariedad.

5. La Función de Autocorrelación (*The Autocorrelation Function*)

La función de autocorrelación / autocorrelation function (ACF) o correlograma / correlogram grafica ρ_s contra s . Las ecuaciones de Yule-Walker / Yule-Walker equations permiten derivarla a partir del modelo.

5.1. ACF de un Proceso AR(1)

Para $y_t = a_0 + a_1 y_{t-1} + \varepsilon_t$:

$$\gamma_0 = \frac{\sigma^2}{1 - (a_1)^2} \quad (17)$$

$$\gamma_s = \frac{\sigma^2 (a_1)^s}{1 - (a_1)^2} \quad (18)$$

Las autocorrelaciones son $\rho_s = (a_1)^s$. Si $a_1 > 0$, la convergencia es directa; si $a_1 < 0$, el patrón es oscilatorio amortiguado.

5.2. ACF de un Proceso AR(2)

Para $y_t = a_1 y_{t-1} + a_2 y_{t-2} + \varepsilon_t$, las ecuaciones de Yule-Walker producen:

$$\rho_1 = \frac{a_1}{1 - a_2} \quad (19)$$

$$\rho_s = a_1 \rho_{s-1} + a_2 \rho_{s-2}, \quad s \geq 2 \quad (20)$$

La varianza es:

$$\gamma_0 = \frac{(1 - a_2)}{(1 + a_2)} \cdot \frac{\sigma^2}{(a_1 + a_2 - 1)(a_2 - a_1 - 1)} \quad (21)$$

5.3. ACF de un Proceso MA(1)

Para $y_t = \varepsilon_t + \beta \varepsilon_{t-1}$:

$$\gamma_0 = (1 + \beta^2) \sigma^2 \quad (22)$$

$$\gamma_1 = \beta \sigma^2 \quad (23)$$

$$\gamma_s = 0 \quad \forall s > 1 \quad (24)$$

Por tanto $\rho_1 = \beta/(1 + \beta^2)$ y $\rho_s = 0$ para $s > 1$. La ACF de un MA(q) tiene exactamente q espigas y luego se corta a cero.

5.4. ACF de un Proceso ARMA(1,1)

Para $y_t = a_1 y_{t-1} + \varepsilon_t + \beta_1 \varepsilon_{t-1}$:

$$\rho_1 = \frac{(1 + a_1 \beta_1)(a_1 + \beta_1)}{1 + \beta_1^2 + 2a_1 \beta_1} \quad (25)$$

y $\rho_s = a_1 \rho_{s-1}$ para $s \geq 2$.

Para un ARMA(p, q) estacionario, la ACF comienza a decaer después del rezago q , satisfaciendo la ecuación en diferencias de la parte AR.

6. La Función de Autocorrelación Parcial (*The Partial Autocorrelation Function*)

La **autocorrelación parcial** / **partial autocorrelation** entre y_t e y_{t-s} elimina el efecto de los valores intermedios $y_{t-1}, \dots, y_{t-s+1}$. La **PACF** (**Partial Autocorrelation Function**) se calcula mediante las ecuaciones de Yule-Walker:

$$\phi_{11} = \rho_1 \quad (26)$$

$$\phi_{22} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} \quad (27)$$

Para rezagos $s = 3, 4, 5, \dots$:

$$\phi_{ss} = \frac{\rho_s - \sum_{j=1}^{s-1} \phi_{s-1,j} \rho_{s-j}}{1 - \sum_{j=1}^{s-1} \phi_{s-1,j} \rho_j} \quad (28)$$

donde $\phi_{sj} = \phi_{s-1,j} - \phi_{ss} \phi_{s-1,s-j}$.

Propiedades clave:

1. Para un AR(p), $\phi_{ss} = 0$ para todo $s > p$: la PACF se corta abruptamente a cero después del rezago p .
2. Para un MA(1), la PACF decae geométricamente (no se corta): el proceso MA(1) tiene una representación AR infinita.
3. Para un ARMA(p, q) estacionario:
 - La **ACF** comienza a decaer después del rezago q .
 - La **PACF** comienza a decaer después del rezago p .

7. Autocorrelaciones Muestrales de Series Estacionarias (*Sample Autocorrelations of Stationary Series*)

Con T observaciones, los estimadores muestrales de μ , σ^2 y ρ_s son:

$$\bar{y} = \frac{1}{T} \sum_{t=1}^T y_t \quad (29)$$

$$\hat{\sigma}^2 = \frac{1}{T} \sum_{t=1}^T (y_t - \bar{y})^2 \quad (30)$$

$$r_s = \frac{\sum_{t=s+1}^T (y_t - \bar{y})(y_{t-s} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2} \quad (31)$$

La varianza muestral de r_s bajo $H_0 : r_s = 0$ (Box-Jenkins, 1976):

$$\text{var}(r_s) = T^{-1} \left(1 + 2 \sum_{j=1}^{s-1} r_j^2 \right), \quad s > 1 \quad (32)$$

En muestras grandes, $r_s \sim N(0, \text{var}(r_s))$.

7.1. Estadísticos Q de Box-Pierce y Ljung-Box

Para probar que un grupo de autocorrelaciones es conjuntamente igual a cero:

Estadístico Q de Box-Pierce:

$$Q = T \sum_{k=1}^s r_k^2 \quad (33)$$

Estadístico Q de Ljung-Box (mejor desempeño en muestras pequeñas):

$$Q = T(T+2) \sum_{k=1}^s \frac{r_k^2}{T-k} \quad (34)$$

Bajo H_0 : todos los $r_k = 0$, $Q \sim \chi^2(s)$. Aplicado a los **residuos** / **residuals** de un ARMA(p, q) estimado, los grados de libertad son $s - p - q$ (o $s - p - q - 1$ si hay constante).

7.2. Criterios de Selección de Modelos (*Model Selection Criteria*)

El principio de **parsimonia** / **parsimony** indica preferir modelos con menos parámetros. Los dos criterios más utilizados son:

AIC (Akaike Information Criterion / Criterio de Información de Akaike):

$$AIC = T \ln(\text{SCR}) + 2n \quad (35)$$

SBC / BIC (Schwartz Bayesian Criterion / Criterio Bayesiano de Schwartz):

$$SBC = T \ln(\text{SCR}) + n \ln(T) \quad (36)$$

donde $n = p + q + \text{constante}$ y T = número de observaciones útiles. Se prefiere el modelo con el AIC o SBC *menor*. El SBC penaliza más fuertemente los parámetros adicionales (es asintóticamente consistente); el AIC puede estar sesgado hacia modelos sobreparametrizados. Ambos criterios permiten comparar modelos *no anidados*.

8. Selección de Modelos Box-Jenkins (*Box-Jenkins Model Selection*)

El enfoque de **Box-Jenkins (1976)** es una estrategia de tres etapas para identificación, estimación y diagnóstico de una serie de tiempo univariada:

1. **Etapas de identificación / identification stage:** Se grafica la trayectoria temporal de la serie y se examinan la ACF y PACF muestrales. Una ACF que decae lentamente sugiere no estacionariedad; en tal caso, se recomienda *diferenciar* los datos.
2. **Etapas de estimación / estimation stage:** Se estiman todos los modelos tentativos; se examinan los coeficientes a_i y β_i para seleccionar un modelo estacionario, **parsimonioso / parsimonious** y con buen ajuste.
3. **Verificación diagnóstica / diagnostic checking:** Se verifica que los **residuos / residuals** del modelo estimado se comporten como ruido blanco.

8.1. Parsimonia (*Parsimony*)

La **parsimonia / parsimony** (escasez o austeridad en parámetros) es un principio fundamental: los modelos parsimoniosos producen mejores pronósticos que los sobreparametrizados. El objetivo es aproximar el verdadero proceso generador de datos sin fijarlo exactamente.

Se debe detectar el **problema del factor común / common factor problem**: si los polinomios AR y MA de un ARMA(p, q) comparten un factor común $(1 + cL)$, el modelo se reduce a uno más parsimonioso.

8.2. Estacionariedad e Invertibilidad (*Stationarity and Invertibility*)

El enfoque Box-Jenkins requiere que el modelo sea **invertible / invertible**: $\{y_t\}$ debe poder representarse mediante un AR finito o convergente. Para que un ARMA sea invertible, las raíces del polinomio $(1 + \beta_1 L + \dots + \beta_q L^q)$ deben estar *fuera* del círculo unitario.

8.3. Bondad de Ajuste (*Goodness of Fit*)

El R^2 y el promedio de la suma de cuadrados residuales son medidas de **bondad de ajuste** / **goodness-of-fit** comunes en MCO; sin embargo, mejoran mecánicamente al agregar parámetros. El AIC y el SBC son medidas más apropiadas del ajuste global porque penalizan la complejidad del modelo. Además, se debe desconfiar de estimaciones que no convergen rápidamente: una búsqueda no lineal que no converge puede indicar parámetros inestables que cambian apreciablemente al añadir una observación.

8.4. Evaluación Postestimación (*Postestimation Evaluation*)

Los residuos deben ser serialmente no correlacionados. Se construyen la ACF y PACF de los residuos y se aplican los estadísticos Q. También se puede comparar la capacidad predictiva fuera de muestra (**out-of-sample forecasts**).

El **sobreajuste** / **overfitting** consiste en ajustar idiosincrasias muestrales que no son representativas del verdadero proceso generador de datos.

9. Propiedades de los Pronósticos (*Properties of Forecasts*)

El uso más importante de un modelo ARMA es pronosticar valores futuros. Para el AR(1) $y_t = a_0 + a_1 y_{t-1} + \varepsilon_t$, el pronóstico condicional un paso adelante es:

$$E_t y_{t+1} = a_0 + a_1 y_t \quad (37)$$

La **función de pronóstico** / **forecast function** expresa todos los pronósticos j pasos adelante:

$$E_t y_{t+j} = a_0(1 + a_1 + a_1^2 + \cdots + a_1^{j-1}) + a_1^j y_t \quad (38)$$

Para cualquier ARMA estacionario, el pronóstico condicional converge a la media incondicional cuando $j \rightarrow \infty$.

El **error de pronóstico** / **forecast error** j pasos adelante:

$$e_t(j) \equiv y_{t+j} - E_t y_{t+j} \quad (39)$$

Para el AR(1):

$$e_t(j) = \varepsilon_{t+j} + a_1 \varepsilon_{t+j-1} + \cdots + a_1^{j-1} \varepsilon_{t+1} \quad (40)$$

La varianza del error de pronóstico es creciente en j :

$$\text{var}[e_t(j)] = \sigma^2 [1 + a_1^2 + a_1^4 + \cdots + a_1^{2(j-1)}] \quad (41)$$

Al límite, $\text{var}[e_t(j)] \rightarrow \sigma^2 / (1 - a_1^2)$, que es la varianza incondicional de $\{y_t\}$.

9.1. Modelos de Orden Superior (*Higher-Order Models*)

Para el ARMA(2,1): $y_t = a_0 + a_1y_{t-1} + a_2y_{t-2} + \varepsilon_t + \beta_1\varepsilon_{t-1}$, el pronóstico un paso adelante es:

$$E_ty_{t+1} = a_0 + a_1y_t + a_2y_{t-1} + \beta_1\varepsilon_t \quad (42)$$

Para $j \geq 2$:

$$E_ty_{t+j} = a_0 + a_1E_ty_{t+j-1} + a_2E_ty_{t+j-2} \quad (43)$$

9.2. Evaluación de Pronósticos (*Forecast Evaluation*)

El error cuadrático medio de pronóstico (MSPE) / mean square prediction error:

$$\text{MSPE} = \frac{1}{H} \sum_{i=1}^H e_{1i}^2 \quad (44)$$

9.2.1. Prueba de Granger-Newbold (*The Granger-Newbold Test*)

Se forman $x_i = e_{1i} + e_{2i}$ y $z_i = e_{1i} - e_{2i}$. El estadístico:

$$\frac{r_{xz}}{\sqrt{(1 - r_{xz}^2)/(H - 1)}} \sim t(H - 1) \quad (45)$$

bajo H_0 de igual desempeño en pronóstico.

9.2.2. Prueba de Diebold-Mariano (*The Diebold-Mariano Test*)

Permite una función de pérdida general $g(\cdot)$. La pérdida diferencial en el período i es $d_i = g(e_{1i}) - g(e_{2i})$:

$$\text{DM} = \bar{d} / \sqrt{\frac{\gamma_0 + 2\gamma_1 + \dots + 2\gamma_q}{H - 1}} \sim t(H - 1) \quad (46)$$

donde γ_i son las autocovarianzas de la secuencia $\{d_i\}$.

10. Un Modelo del Diferencial de Tasas de Interés (*A Model of the Interest Rate Spread*)

Esta sección ilustra las ambigüedades prácticas de Box-Jenkins. El **diferencial de tasas / interest rate spread** s_t es la diferencia entre la tasa de bonos a 5 años y la tasa de letras del Tesoro a 3 meses.

Puntos clave de la aplicación:

- La ACF y PACF son ambiguas; múltiples modelos plausibles (AR(2), AR(6), AR(7), ARMA(1,1), ARMA(2,1)) se justifican.
- El AIC y el SBC pueden recomendar modelos distintos.

- El **sobreaajuste / overfitting** surge al ajustar idiosincrasias muestrales no representativas del verdadero proceso.
- Los pronósticos fuera de muestra sirven como criterio adicional de selección.

11. Estacionalidad (*Seasonality*)

Muchos procesos económicos exhiben **estacionalidad / seasonality**. Se debe ser cauteloso con datos **desestacionalizados / deseasonalized** o **ajustados estacionalmente / seasonally adjusted**, pues puede persistir un patrón estacional residual, especialmente si no se usa toda la muestra disponible.

11.1. Modelos de Datos Estacionales (*Models of Seasonal Data*)

Dos modelos puramente estacionales para datos trimestrales (período $s = 4$):

$$y_t = a_4 y_{t-4} + \varepsilon_t, \quad |a_4| < 1 \quad (47)$$

$$y_t = \varepsilon_t + \beta_4 \varepsilon_{t-4} \quad (48)$$

La **estacionalidad multiplicativa / multiplicative seasonality** permite la interacción entre efectos ARMA estacionales y no estacionales:

$$(1 - a_1 L) y_t = (1 + \beta_1 L)(1 + \beta_4 L^4) \varepsilon_t \quad (49)$$

$$(1 - a_1 L)(1 - a_4 L^4) y_t = (1 + \beta_1 L) \varepsilon_t \quad (50)$$

11.2. Diferenciación Estacional (*Seasonal Differencing*)

Cuando hay no estacionariedad con fuerte estacionalidad, se toma la **diferencia estacional**. Para datos trimestrales: $\Delta_4 y_t = y_t - y_{t-4}$.

Combinando diferenciación regular y estacional se obtiene el **ARIMA**(p, d, q)(P, D, Q) $_s$:

- p, q : coeficientes ARMA no estacionales
- d : número de diferencias regulares
- P, D, Q : coeficientes AR, diferencias y MA multiplicativos estacionales
- s : período estacional

El modelo ARIMA(0,1,1)(0,1,1) $_s$ es el **modelo airline / airline model** (Box y Jenkins, 1976).

12. Inestabilidad de Parámetros y Cambio Estructural (*Parameter Instability and Structural Change*)

Un supuesto clave de Box-Jenkins es que la estructura del proceso generador de datos no cambia. Si los coeficientes a_i y β_i varían en el tiempo, el modelo está mal especificado.

12.1. Prueba de Cambio Estructural (*Testing for Structural Change*)

La **prueba de Chow / Chow test** divide la muestra en dos subperíodos en torno a la fecha t_m y verifica si los coeficientes difieren significativamente:

$$F = \frac{(\text{SCR} - \text{SCR}_1 - \text{SCR}_2)/n}{(\text{SCR}_1 + \text{SCR}_2)/(T - 2n)} \sim F(n, T - 2n) \quad (51)$$

donde $n = p + q + 1$ y $\text{SCR}_1, \text{SCR}_2$ son las sumas de cuadrados residuales de cada subperíodo.

12.2. Quiebres Endógenos (*Endogenous Breaks*)

Un **quiebre endógeno / endogenous break** ocurre en una fecha no especificada previamente. Se busca el quiebre más probable estimando la prueba de Chow para cada período dentro de una franja de **recorte / trimming** (típicamente el 10 % en cada extremo). La distribución del F -máximo no es estándar; se usan valores críticos de Andrews y Ploberger (1994).

12.3. Inestabilidad de Parámetros (*Parameter Instability*)

Sin una fecha de quiebre clara, se usa **estimación recursiva**: se estima el modelo secuencialmente añadiendo una observación a la vez y se grafican los coeficientes con bandas ± 2 desviaciones estándar.

La prueba **CUSUM** acumula los errores de pronóstico estandarizados un paso adelante:

$$\text{CUSUM}_N = \sum_{i=n}^N \frac{e_i(1)}{\sigma_e}, \quad N = n, \dots, T - 1 \quad (52)$$

Al nivel del 5 %, el CUSUM debe permanecer dentro de la banda:

$$\pm 0,948[(T - n)^{0,5} + 2(N - n)(T - n)^{-0,5}] \quad (53)$$

Una variante, **CUSUM(2)**, utiliza errores cuadrados y detecta cambios en la varianza.

13. Combinación de Pronósticos (*Combining Forecasts*)

Ante varios modelos plausibles, combinar sus pronósticos reduce el error. El **pronóstico compuesto / composite forecast** con n modelos:

$$f_{ct} = w_1 f_{1t} + w_2 f_{2t} + \dots + w_n f_{nt}, \quad \sum_{i=1}^n w_i = 1 \quad (54)$$

La varianza del error compuesto (para $n = 2$):

$$\begin{aligned} \text{var}(e_{ct}) = & w_1^2 \text{var}(e_{1t}) + (1 - w_1)^2 \text{var}(e_{2t}) \\ & + 2w_1(1 - w_1) \text{cov}(e_{1t}, e_{2t}) \end{aligned} \quad (55)$$

13.1. Pesos Óptimos (*Optimal Weights*)

El peso óptimo para el modelo 1 cuando $\text{cov}(e_{1t}, e_{2t}) = 0$:

$$w_1^* = \frac{\text{var}(e_{2t})}{\text{var}(e_{1t}) + \text{var}(e_{2t})} \quad (56)$$

Para n modelos (método de Granger–Ramanathan, 1984):

$$w_n^* = \frac{[\text{var}(e_{nt})]^{-1}}{\sum_{i=1}^n [\text{var}(e_{it})]^{-1}} \quad (57)$$

Alternativamente, se estima la regresión:

$$y_t = a_0 + \alpha_1 f_{1t} + \alpha_2 f_{2t} + \cdots + \alpha_n f_{nt} + v_t \quad (58)$$

El SBC también puede usarse como factor de ponderación: $\alpha_i = \exp[(\text{SBC}^* - \text{SBC}_i)/2]$, donde SBC^* es el máximo valor del SBC entre los modelos.

14. Resumen y Conclusiones (*Summary and Conclusions*)

El capítulo desarrolla el enfoque Box-Jenkins para la identificación, estimación, verificación diagnóstica y pronóstico de series de tiempo univariadas. Los puntos centrales son:

- Un modelo ARMA es estacionario en covarianza si tiene media y varianzas finitas e invariantes en el tiempo; las raíces características deben estar dentro del círculo unitario y el proceso debe haber comenzado infinitamente en el pasado.
- Una ACF que decae lentamente sugiere no estacionariedad; Box y Jenkins recomiendan diferenciar los datos. Si la varianza no es constante, se aplican transformaciones logarítmicas o Box-Cox.
- Un modelo bien estimado cumple: (i) es parsimonioso; (ii) implica estacionariedad e invertibilidad; (iii) ajusta bien los datos; (iv) tiene residuos aproximadamente ruido blanco; (v) tiene coeficientes estables en el tiempo; y (vi) produce buenos pronósticos fuera de muestra.
- La inestabilidad de coeficientes se detecta con la prueba de Chow (quiebre conocido), estimación recursiva, o la prueba CUSUM (quiebre desconocido).
- En general, los **pronósticos combinados / combined forecasts** superan a los pronósticos de un solo modelo (*ad hoc* o mediante pesos óptimos).