

Resumen: Stock & Watson, Capítulo 14

(Secciones 14.3–14.8)

Introducción a la regresión de series temporales y predicción

Índice

1. Autorregresión (<i>Autoregression</i>)	2
1.1. Modelo AR(1)	2
1.2. Modelo AR(p)	2
1.3. Predicciones y error de predicción	2
2. Regresión de Series Temporales con Predictores Adicionales y Causalidad de Granger	3
2.1. Modelo ARD(p,q)	3
2.2. Concepto 14.5: Estacionariedad	3
2.3. Concepto 14.6: Regresión de Series Temporales con Varios Predictores	3
2.4. Concepto 14.7: Causalidad de Granger	3
2.5. Incertidumbre e Intervalos de Predicción	3
3. Selección de la Longitud del Retardo Usando Criterios de Información	4
3.1. Criterio de Información Bayesiano (BIC)	4
3.2. Criterio de Información de Akaike (AIC)	4
3.3. BIC para Modelos ARD	4
4. Ausencia de Estacionariedad I: Tendencias	5
4.1. Tendencias Determinísticas versus Estocásticas	5
4.2. Paseo Aleatorio	5
4.3. Regresión Espuria	5
4.4. Contrastes de Raíz Unitaria: Dickey-Fuller	5
4.5. Concepto 14.8: Contraste Dickey-Fuller Aumentado (ADF)	6
4.6. Resolución: Primeras Diferencias	6
5. Ausencia de Estacionariedad II: Cambios Estructurales	6
5.1. Qué es un Cambio Estructural	6
5.2. Contraste de Cambio Estructural con Punto de Ruptura Conocido (Contraste de Chow)	6
5.3. Concepto 14.9: El Contraste QLR (Punto de Ruptura Desconocido)	7

5.4. Predicción Pseudo Fuera de la Muestra	7
5.5. Resolución de Cambios Estructurales	8
6. Conclusión	8

1. Autorregresión (*Autoregression*)

1.1. Modelo AR(1)

El **modelo autorregresivo de orden 1 / autoregressive model of order 1 (AR(1))** expresa el valor actual de una variable como función lineal de su valor en el periodo anterior más un término de error:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + u_t, \quad (1)$$

donde u_t es un error con media cero condicionada al pasado. El coeficiente β_1 mide la persistencia de la serie: si $|\beta_1| < 1$, la serie es estacionaria; si $\beta_1 = 1$, la serie sigue un **paseo aleatorio / random walk**.

1.2. Modelo AR(p)

Generalizando, el **modelo AR(p)** incluye p retardos de la variable dependiente:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \cdots + \beta_p Y_{t-p} + u_t. \quad (2)$$

Los parámetros se estiman por **mínimos cuadrados ordinarios / ordinary least squares (MCO/OLS)**. El orden p se determina minimizando un **criterio de información / information criterion** (BIC o AIC).

1.3. Predicciones y error de predicción

La **predicción de un periodo adelante / one-period-ahead forecast** del modelo AR(1) es:

$$\hat{Y}_{T+1|T} = \hat{\beta}_0 + \hat{\beta}_1 Y_T. \quad (3)$$

Para horizontes más largos se calculan **predicciones iteradas / iterated forecasts**, sustituyendo predicciones previas como si fueran valores observados.

La precisión de la predicción se mide con la **raíz del error cuadrático medio de predicción / root mean squared forecast error (RECMF/RMSFE)**:

$$\text{RECMF} = \sqrt{E \left[\left(Y_{T+1} - \hat{Y}_{T+1|T} \right)^2 \right]}. \quad (4)$$

Un **intervalo de predicción / forecast interval** aproximado al 95 % es:

$$\hat{Y}_{T+1|T} \pm 1,96 \times \text{RECMF}. \quad (5)$$

2. Regresión de Series Temporales con Predictores Adicionales y Causalidad de Granger

2.1. Modelo ARD(p,q)

El **modelo autorregresivo de retardos distribuidos / autoregressive distributed lag model (ARD/ADL)** extiende el AR(p) incorporando retardos de variables adicionales X_t :

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \cdots + \beta_p Y_{t-p} + \delta_1 X_{t-1} + \cdots + \delta_q X_{t-q} + u_t. \quad (6)$$

Añadir predictores adicionales puede mejorar la predicción si dichos predictores están correlacionados con Y_t tras controlar por sus propios retardos.

2.2. Concepto 14.5: Estacionariedad

Una serie de tiempo Y_t es **estacionaria / stationary** si su distribución conjunta no cambia a lo largo del tiempo; en particular, su media y varianza son constantes y su autocovarianza entre Y_t e Y_{t-j} depende solo de j , no de t . La estacionariedad es necesaria para que la inferencia estándar con MCO sea válida en series temporales.

2.3. Concepto 14.6: Regresión de Series Temporales con Varios Predictores

Bajo los supuestos de MCO para series temporales (Concepto 14.6), los estimadores MCO son consistentes y asintóticamente normales, de modo que los estadísticos t y F pueden compararse con los valores críticos habituales en muestras grandes. Los supuestos clave son: (i) estacionariedad; (ii) ausencia de multicolinealidad perfecta; (iii) media condicional del error nula; (iv) ausencia de autocorrelación serial en los errores, y (v) los momentos necesarios son finitos.

2.4. Concepto 14.7: Causalidad de Granger

Se dice que X_t **causa en el sentido de Granger / Granger-causes** a Y_t si los retardos de X_t tienen poder predictivo adicional sobre Y_t después de controlar por los retardos de Y_t y eventualmente de otras variables. Formalmente, la hipótesis nula de no-causalidad Granger es $\delta_1 = \delta_2 = \cdots = \delta_q = 0$ en el modelo ARD(p,q), contrastada mediante el estadístico F . La causalidad de Granger es un concepto predictivo, no causal en sentido estructural.

2.5. Incertidumbre e Intervalos de Predicción

El **error cuadrático medio de predicción (ECMP) / mean squared forecast error (MSFE)** resume las dos fuentes de incertidumbre en la predicción: la varianza del término de error futuro y la varianza de estimación de los coeficientes. En muestras grandes, la segunda fuente es pequeña y el ECMP se aproxima a la varianza del error:

$$\text{ECMP} = \sigma_u^2 + \text{varianza de estimación} \approx \sigma_u^2. \quad (7)$$

Los intervalos de predicción se construyen usando la RECMP estimada como medida de dispersión.

3. Selección de la Longitud del Retardo Usando Criterios de Información

El número de retardos p en un $\text{AR}(p)$ o $\text{ARD}(p,q)$ se elige minimizando un **criterio de información** / **information criterion** que penaliza la complejidad del modelo.

3.1. Criterio de Información Bayesiano (BIC)

El **criterio BIC** / **Bayesian information criterion (BIC)** para el $\text{AR}(p)$ es:

$$\text{BIC}(p) = \ln\left(\frac{\text{SCR}(p)}{T}\right) + (p+1)\frac{\ln T}{T}, \quad (8)$$

donde $\text{SCR}(p)$ es la suma de cuadrados de los residuos del modelo con p retardos. El orden elegido es $\hat{p}_{\text{BIC}} = \arg \min_p \text{BIC}(p)$.

3.2. Criterio de Información de Akaike (AIC)

El **criterio AIC** / **Akaike information criterion (AIC)** es:

$$\text{AIC}(p) = \ln\left(\frac{\text{SCR}(p)}{T}\right) + (p+1)\frac{2}{T}. \quad (9)$$

El AIC penaliza los parámetros adicionales menos que el BIC. Para muestras grandes, el BIC es consistente (selecciona el verdadero orden con probabilidad 1 cuando $T \rightarrow \infty$), mientras que el AIC tiende a sobrestimar el orden.

3.3. BIC para Modelos ARD

Para el modelo ARD con K regresores en total (incluyendo retardos de Y_t y de predictores adicionales), el BIC generalizado es:

$$\text{BIC}(K) = \ln\left(\frac{\text{SCR}(K)}{T}\right) + (K+1)\frac{\ln T}{T}. \quad (10)$$

La práctica habitual consiste en fijar un máximo de retardos $p_{\text{máx}}$ (por ejemplo, tomado como $\lfloor T^{1/3} \rfloor$) y evaluar el BIC para todos los valores $p = 1, \dots, p_{\text{máx}}$.

4. Ausencia de Estacionariedad I: Tendencias

4.1. Tendencias Determinísticas versus Estocásticas

Una **tendencia** / **trend** en una serie de tiempo puede ser:

- **Determinística** / **deterministic**: el nivel medio de la serie crece de forma predecible en el tiempo; por ejemplo, $E[Y_t] = \beta_0 + \beta_1 t$.
- **Estocástica** / **stochastic**: el nivel de la serie varía de forma impredecible, acumulando perturbaciones aleatorias.

4.2. Paseo Aleatorio

El **paseo aleatorio** / **random walk** es el modelo de tendencia estocástica más simple:

$$Y_t = Y_{t-1} + u_t, \quad (11)$$

donde u_t es ruido blanco. La varianza de Y_t crece con t , por lo que la serie es no estacionaria. El **paseo aleatorio con deriva** / **random walk with drift** añade un término constante:

$$Y_t = \beta_0 + Y_{t-1} + u_t, \quad (12)$$

lo que genera una tendencia lineal en la media.

4.3. Regresión Espuria

Cuando dos series no estacionarias se regresan entre sí sin que exista una relación económica real, el estimador MCO puede arrojar coeficientes significativos y un R^2 elevado de manera ficticia. Este fenómeno se denomina **regresión espuria** / **spurious regression** y constituye una de las principales razones para estudiar la estacionariedad antes de estimar modelos de regresión con series temporales.

4.4. Contrastes de Raíz Unitaria: Dickey-Fuller

El **contraste de Dickey-Fuller** / **Dickey-Fuller test (DF)** contrasta la hipótesis nula $H_0: \delta = 0$ (raíz unitaria) frente a la alternativa $H_1: \delta < 0$ (estacionariedad) en la regresión:

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + u_t, \quad (13)$$

donde $\Delta Y_t = Y_t - Y_{t-1}$. El estadístico es el t MCO para $\hat{\delta}$, pero su distribución bajo H_0 no es normal estándar incluso en muestras grandes, por lo que se utilizan valores críticos especiales (Tabla 14.5 del libro).

4.5. Concepto 14.8: Contraste Dickey-Fuller Aumentado (ADF)

El **contraste de Dickey-Fuller aumentado / augmented Dickey-Fuller test (ADF)** extiende el DF agregando retardos de ΔY_t para controlar la autocorrelación serial:

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \gamma_1 \Delta Y_{t-1} + \gamma_2 \Delta Y_{t-2} + \cdots + \gamma_p \Delta Y_{t-p} + u_t. \quad (14)$$

Si la alternativa es estacionariedad alrededor de una tendencia temporal lineal, se añade el regresor t a la regresión:

$$\Delta Y_t = \beta_0 + \alpha t + \delta Y_{t-1} + \gamma_1 \Delta Y_{t-1} + \cdots + \gamma_p \Delta Y_{t-p} + u_t. \quad (15)$$

El número de retardos p puede elegirse con BIC o AIC. Los valores críticos del ADF son menores (más negativos) que los de la distribución normal: al 5 % son $-2,86$ (sin tendencia) y $-3,41$ (con tendencia).

4.6. Resolución: Primeras Diferencias

Si una serie tiene una raíz unitaria, la manera más común de eliminar la tendencia estocástica es tomar **primeras diferencias / first differences**. Si Y_t sigue un paseo aleatorio con deriva, entonces $\Delta Y_t = \beta_0 + u_t$ es estacionaria.

5. Ausencia de Estacionariedad II: Cambios Estructurales

5.1. Qué es un Cambio Estructural

Un **cambio estructural / structural break** ocurre cuando los coeficientes de la función de regresión poblacional varían durante el período muestral. Los cambios pueden ser **discretos / discrete** (en un momento específico) o de **evolución lenta / slow-moving** (graduales a lo largo del tiempo). Si no se detectan, el modelo MCO estima una relación “promedio” que puede ser muy diferente de la verdadera al final de la muestra, conduciendo a predicciones sesgadas.

5.2. Contraste de Cambio Estructural con Punto de Ruptura Conocido (Contraste de Chow)

Si la fecha del cambio estructural τ es conocida, se especifica una **variable binaria de cambio estructural / structural break dummy** $D_t(\tau)$, que vale 0 para $t \leq \tau$ y 1 para $t > \tau$. En un modelo ARD(1,1) la regresión ampliada es:

$$Y_t = \beta_0 + \beta_1 Y_{t-1} + \delta_1 X_{t-1} + \gamma_0 D_t(\tau) + \gamma_1 [D_t(\tau) \times Y_{t-1}] + \gamma_2 [D_t(\tau) \times X_{t-1}] + u_t. \quad (16)$$

La hipótesis nula de ausencia de cambio estructural es $\gamma_0 = \gamma_1 = \gamma_2 = 0$, contrastada con el **estadístico F de Chow / Chow F -statistic**.

5.3. Concepto 14.9: El Contraste QLR (Punto de Ruptura Desconocido)

Cuando el momento del cambio es desconocido, el **estadístico QLR / QLR statistic** (también llamado **estadístico supWald**) es el máximo de los estadísticos F de Chow calculados para todos los posibles puntos de ruptura en el rango $\tau_0 \leq \tau \leq \tau_1$:

$$\text{QLR} = \max[F(\tau_0), F(\tau_0 + 1), \dots, F(\tau_1)]. \quad (17)$$

En la práctica se aplica una **reducción del 15 % / 15 % trimming**, de modo que $\tau_0 = 0,15T$ y $\tau_1 = 0,85T$; el estadístico F se calcula solo en el 70 % central de la muestra. Los valores críticos del QLR (Tabla 14.6) son mayores que los del F individual porque el QLR elige el máximo entre muchos estadísticos F .

Las propiedades del contraste QLR son:

1. Puede contrastar cambios en todos o en un subconjunto de los coeficientes.
2. En muestras grandes, su distribución bajo H_0 depende de q (número de restricciones) y de los extremos de reducción τ_0/T , τ_1/T .
3. Detecta tanto un único cambio discreto como múltiples cambios o evolución lenta de los coeficientes.
4. Cuando existe un cambio estructural discreto, el punto de ruptura τ se estima como el periodo donde el estadístico F es máximo.

5.4. Predicción Pseudo Fuera de la Muestra

La **predicción pseudo fuera de la muestra / pseudo out-of-sample forecasting** evalúa el rendimiento de un modelo en condiciones similares a las del tiempo real, sin usar datos futuros en la estimación. El procedimiento (Concepto 14.10) es:

1. Elegir un número de predicciones P (por ejemplo, el 10–15 % del total de observaciones T); sea $s = T - P$.
2. Estimar el modelo con los datos $t = 1, \dots, s$.
3. Calcular la predicción $\tilde{Y}_{s+1|s}$ y el error $\tilde{u}_{s+1} = Y_{s+1} - \tilde{Y}_{s+1|s}$.
4. Repetir los pasos 2–3 para $s = T - P, T - P + 1, \dots, T - 1$, reestimando el modelo en cada periodo.
5. Las predicciones pseudo fuera de la muestra son $\{\tilde{Y}_{s+1|s}\}$ y los errores $\{\tilde{u}_{s+1}\}$.

La desviación típica muestral de los errores de predicción pseudo fuera de la muestra es un estimador de la RECOMP, útil para cuantificar la incertidumbre de predicción y para comparar modelos alternativos.

5.5. Resolución de Cambios Estructurales

Si el cambio estructural es discreto y puede detectarse con el QLR, la función de regresión se reestima incorporando la variable binaria de ruptura $D_t(\hat{\tau})$ con sus interacciones. Si el cambio es de evolución lenta, los métodos disponibles quedan fuera del alcance introductorio de este capítulo.

6. Conclusión

El capítulo 14 introduce los fundamentos de la regresión de series temporales para la predicción. Los puntos centrales son:

1. Los modelos de predicción no requieren interpretación causal; el objetivo es la precisión predictiva.
2. Las series temporales suelen estar **serialmente correlacionadas** / **serially correlated**, lo que motiva el uso de modelos AR y ARD.
3. El orden de los retardos se determina minimizando el BIC (consistente) o el AIC.
4. La **estacionariedad** / **stationarity** es el supuesto clave para la validez de la inferencia MCO estándar.
5. Las series con **raíces unitarias** / **unit roots** son no estacionarias; el contraste ADF permite detectarlas. La primera diferencia elimina la tendencia estocástica.
6. Los **cambios estructurales** / **structural breaks** invalidan la estabilidad del modelo. El contraste QLR permite detectarlos incluso cuando la fecha es desconocida.
7. La predicción pseudo fuera de la muestra evalúa el rendimiento real del modelo y estima la RECMP.
8. Cuando la no estacionariedad proviene de un cambio estructural discreto, el modelo puede reestimarse incorporando la ruptura identificada.